

Práctica III - Parte 1

Tema 6: Cópulas

Autores:

Alejandro Martínez
Antón Salvadores

Profesor: Ángel León
Fecha: 13 de febrero de 2026

Exercise 1

Consider the following points: $A = (1, 0)$, $B = (5, 0)$ and $C = (3, \frac{1}{2})$. Let $\overline{AC}$ be the equation of the line passing through the points A and C , and $\overline{BC}$ the equation of the line passing through B and C .

- i) Find the lines $\overline{AC}$ and $\overline{BC}$. Obtain the expression for the function $f(x)$ where:

$$f(x) = \begin{cases} \overline{AC} & \text{for } 1 \leq x \leq 3 \\ \overline{BC} & \text{for } 3 < x \leq 5 \\ 0 & \text{in other cases} \end{cases}$$

- ii) Plot the graph of $f(x)$ and verify that it is a probability density function (pdf).

Resolución:

- i) Las líneas $\overline{AC}$ y $\overline{BC}$ son las ecuaciones de las rectas que unen esos puntos.

- a) Recta para $\overline{AC}$:

La pendiente que une los puntos $A = (1, 0)$ y $C = (3, 1/2)$ es $m = \frac{1/2-0}{3-1} = \frac{1}{4}$. Empleando la ecuación para la recta, partiendo desde el punto A , se tiene $y - 0 = m(x - 1) \Rightarrow y = \frac{x-1}{4} \Rightarrow \overline{AC} = \frac{x-1}{4}$.


- b) Recta para $\overline{BC}$:

La pendiente que une los puntos $B = (5, 0)$ y $C = (3, 1/2)$ es $m = \frac{0-1/2}{5-3} = -\frac{1}{4}$. Empleando la ecuación para la recta, partiendo desde el punto B , se tiene $y - 0 = m(x - 5) \Rightarrow y = \frac{5-x}{4} \Rightarrow \overline{BC} = \frac{5-x}{4}$.

Por tanto, la pdf $f(x)$ de esta distribución triangular es la siguiente:

$$f(x) = \begin{cases} \frac{x-1}{4} & \text{for } 1 \leq x \leq 3 \\ \frac{5-x}{4} & \text{for } 3 < x \leq 5 \\ 0 & \text{in other cases} \end{cases}$$

- ii) Representación gráfica y verificación:



Para verificar que es una pdf, debemos integrar sobre x y ver que la integral es igual a 1. En efecto,

$$\begin{aligned}
 \int_{-\infty}^{+\infty} f(x)dx &= \int_1^5 f(x)dx = \int_1^3 f(x)dx + \int_3^5 f(x)dx = \\
 \int_1^3 \frac{x-1}{4}dx + \int_3^5 \frac{5-x}{4}dx &= \frac{1}{4} \left[\frac{x^2}{2} - x \right]_1^3 + \frac{1}{4} \left[5x - \frac{x^2}{2} \right]_3^5 = \\
 \frac{1}{4} \left[\left(\frac{3^2}{2} - 3 \right) - \left(\frac{1^2}{2} - 1 \right) \right] &+ \frac{1}{4} \left[\left(5(5) - \frac{5^2}{2} \right) - \left(5(3) - \frac{3^2}{2} \right) \right] = \\
 \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 &= 1,
 \end{aligned}$$

como queríamos probar.

Exercise 2

The previous exercise is related to the Triangular (Tr) distribution, denoted as $X \sim Tr(a, b, c)$ where $a < c < b$, with the points: $A = (a, 0)$, $B = (b, 0)$ and $C = (c, \frac{2}{b-a})$. Answer the questions:

- I) Obtain $f(x)$ and $F(x)$ corresponding to the pdf and cdf of $X \sim Tr(a, b, c)$.
- II) Compute $\mu_X = E(X)$ and $\sigma_X^2 = V(X)$.
- III) Find the expression of $X = F^{-1}(U)$ where $U \sim U(0, 1)$. Generate 10,000 draws of $X \sim Tr(1, 5, 3)$. Plot the graph of $f(x)$, already obtained in Exercise 1, joint with the histogram of the draws.

Hint: See https://en.wikipedia.org/wiki/Triangular_distribution

Resolución:

- i) La pdf $f(x)$ es la misma que en el ejercicio anterior. Generalizando para los A , B y C descritos en este ejercicio:

$$f(x) = \begin{cases} \overline{AC} & \text{for } a \leq x \leq c \\ \overline{BC} & \text{for } c < x \leq b \\ 0 & \text{in other cases} \end{cases}$$

Ahora, dados estos puntos cualesquiera, describamos $\overline{AC}$ y $\overline{BC}$:

- a) Recta para $\overline{AC}$:

La pendiente que une los puntos $A = (a, 0)$ y $C = (c, \frac{2}{b-a})$ es $m = \frac{\frac{2}{b-a} - 0}{c - a} = \frac{2}{(b-a)(c-a)}$. Empleando la ecuación para la recta, partiendo desde el punto A , se tiene $y - 0 = m(x - a) \Rightarrow y = \frac{2(x-a)}{(b-a)(c-a)} \Rightarrow \overline{AC} = \frac{2(x-a)}{(b-a)(c-a)}$.

- b) Recta para $\overline{BC}$:

La pendiente que une los puntos $B = (b, 0)$ y $C = (c, \frac{2}{b-a})$ es $m = \frac{0 - \frac{2}{b-a}}{b - c} = -\frac{2}{(b-a)(b-c)}$. Empleando la ecuación para la recta, partiendo desde el punto B , se tiene $y - 0 = m(x - b) \Rightarrow y = \frac{2(b-x)}{(b-a)(b-c)} \Rightarrow \overline{BC} = \frac{2(b-x)}{(b-a)(b-c)}$.

Por tanto, la pdf $f(x)$ es la siguiente,

$$f(x) = \begin{cases} \frac{2(x-a)}{(b-a)(c-a)} & \text{for } a \leq x \leq c \\ \frac{2(b-x)}{(b-a)(b-c)} & \text{for } c < x \leq b \\ 0 & \text{in other cases} \end{cases}$$

que es la misma pdf que se indica en la ayuda.

Para obtener la cdf o $F(x)$, tendremos que integrar desde $-\infty$ hasta x la pdf o $f(x)$. Dado que la pdf(x) es un triángulo y está conformado por rectas al integrarla nos saldrá un resultado de polinomios de segundo grado. Para ello, es más sencillo si dividimos la pdf(x) en trozos e integramos por tramos, siendo el tramo de subida desde a hasta c , y el tramo de bajada desde c hasta b :

El tramo de subida por tanto se obtiene integrando esa parte de la pdf(x) siendo a el límite inferior de la integral:

$$F(x) = \int_a^x \frac{2(u-a)}{(b-a)(c-a)} du = \frac{(x-a)^2}{(b-a)(c-a)} \quad \text{para } a \leq x \leq c$$

Para calcular el área de la otra mitad, calculamos el complementario, ya que la integral completa de la pdf(x) vale uno:

$$F(x) = 1 - \frac{(b-x)^2}{(b-a)(b-c)} \quad \text{para } c < x \leq b$$

La cdf(x) definida a trozos quedaría:

$$F(x) = \begin{cases} 0 & x < a \\ \frac{(x-a)^2}{(b-a)(c-a)} & a \leq x \leq c \\ 1 - \frac{(b-x)^2}{(b-a)(b-c)} & c < x \leq b \\ 1 & x > b \end{cases}$$

Tal y como mencionamos anteriormente, se demuestra que la solución son polinomios de 2º grado.

- II) A continuación calcularemos la esperanza y varianza de esta probabilidad de distribución acumulada.

a) La esperanza de una distribución triangular es:

$$\begin{aligned} \mu_X = E(X) &= \int_{-\infty}^{+\infty} xf(x)dx = \int_a^b xf(x)dx = \int_a^c xf(x)dx + \int_c^b xf(x)dx = \\ &= \int_a^c x \frac{2(x-a)}{(b-a)(c-a)} dx + \int_c^b x \frac{2(b-x)}{(b-a)(b-c)} dx = \end{aligned}$$

$$\begin{aligned}
& \frac{1}{(b-a)(c-a)} \int_a^c 2x^2 - 2ax \, dx + \frac{1}{(b-a)(b-c)} \int_c^b 2bx - 2x^2 \, dx = \\
& \frac{1}{(b-a)(c-a)} \left[\frac{2x^3}{3} - ax^2 \right]_a^c + \frac{1}{(b-a)(b-c)} \left[bx^2 - \frac{2x^3}{3} \right]_c^b = \\
& \frac{\frac{2c^3}{3} - ac^2 - \frac{2a^3}{3} + a^3}{(b-a)(c-a)} + \frac{b^3 - \frac{2b^3}{3} - bc^2 + \frac{2c^3}{3}}{(b-a)(b-c)} = \\
& \frac{2c^3 - 3ac^2 + a^3}{3(b-a)(c-a)} + \frac{b^3 - 3bc^2 + 2c^3}{3(b-a)(b-c)} = \\
& \frac{(2c^3 - 3ac^2 + a^3)(b-c) + (b^3 - 3bc^2 + 2c^3)(c-a)}{3(b-a)(c-a)(b-c)} = \\
& \frac{(2bc^3 - 2c^4 - 3abc^2 + 3ac^3 + a^3b - a^3c) + (b^3c - ab^3 - 3bc^3 + 3abc^2 + 2c^4 - 2ac^3)}{3(b-a)(c-a)(b-c)} = \\
& \frac{ac^3 - bc^3 - a^3c + b^3c - ab^3 + a^3b}{3(b-a)(c-a)(b-c)}
\end{aligned}$$

Este es un resultado diferente al encontrado en la ayuda de la Wikipedia. Trataremos de factorizar el numerador para ir cancelando los factores del denominador e intentar alcanzar el resultado deseado:

$$\begin{aligned}
\mu_X &= \frac{c^3(a-b) - c(a^3 - b^3) + (a^3b - ab^3)}{3(b-a)(c-a)(b-c)} = \\
& \frac{c^3(a-b) - c(a-b)(a^2 + ab + b^2) + ab(a-b)(a+b)}{3(b-a)(c-a)(b-c)} = \\
& \frac{-c^3 + c(a^2 + ab + b^2) - ab(a+b)}{3(c-a)(b-c)} = \\
& \frac{-c(c^2 - a^2) + b^2(c-a) + ab(c-a)}{3(c-a)(b-c)} = \\
& \frac{-c(c-a)(c+a) + b^2(c-a) + ab(c-a)}{3(c-a)(b-c)} = \\
& \frac{-c(c+a) + b^2 + ab}{3(b-c)} = \frac{-(c-b)(c+b) - a(c-b)}{3(b-c)} = \frac{a+b+c}{3}
\end{aligned}$$

como se quería demostrar.

b) La varianza de una distribución triangular es

$$\sigma_X^2 = V(X) = E(X^2) - \mu_X^2 = \int_{-\infty}^{+\infty} x^2 f(x) dx - \frac{(a+b+c)^2}{9},$$

así que nos centraremos en el cálculo de la integral para resolverla. Hagámoslo:

$$\begin{aligned}
E(X^2) &= \int_{-\infty}^{+\infty} x^2 f(x) dx = \int_a^b x^2 f(x) dx = \int_a^c x^2 f(x) dx + \int_c^b x^2 f(x) dx = \\
&= \int_a^c x^2 \frac{2(x-a)}{(b-a)(c-a)} dx + \int_c^b x^2 \frac{2(b-x)}{(b-a)(b-c)} dx = \\
&= \frac{1}{(b-a)(c-a)} \int_a^c 2x^3 - 2ax^2 dx + \frac{1}{(b-a)(b-c)} \int_c^b 2bx^2 - 2x^3 dx = \\
&= \frac{1}{(b-a)(c-a)} \left[\frac{x^4}{2} - \frac{2ax^3}{3} \right]_a^c + \frac{1}{(b-a)(b-c)} \left[\frac{2bx^3}{3} - \frac{x^4}{2} \right]_c^b = \\
&= \frac{\frac{c^4}{2} - \frac{2ac^3}{3} - \frac{a^4}{2} + \frac{2a^4}{3}}{(b-a)(c-a)} + \frac{\frac{2b^4}{3} - \frac{b^4}{2} - \frac{2bc^3}{3} + \frac{c^4}{2}}{(b-a)(b-c)} = \\
&= \frac{3c^4 - 4ac^3 + a^4}{6(b-a)(c-a)} + \frac{b^4 - 4bc^3 + 3c^4}{6(b-a)(b-c)} = \\
&= \frac{(3c^4 - 4ac^3 + a^4)(b-c) + (b^4 - 4bc^3 + 3c^4)(c-a)}{6(b-a)(c-a)(b-c)} = \\
&= \frac{(3bc^4 - 3c^5 - 4abc^3 + 4ac^4 + a^4b - a^4c) + (b^4c - ab^4 - 4bc^4 + 4abc^3 + 3c^5 - 3ac^4)}{6(b-a)(c-a)(b-c)} = \\
&= \frac{ac^4 - bc^4 + a^4b - a^4c + b^4c - ab^4}{6(b-a)(c-a)(b-c)}
\end{aligned}$$

Como en el caso de la media, llegamos a una expresión difícil de tratar y la simplificaremos a base de factorizar el numerador.

$$\begin{aligned}
E(X^2) &= \frac{c^4(a-b) - c(a^4 - b^4) + ab(a^3 - b^3)}{6(b-a)(c-a)(b-c)} = \\
&= \frac{c^4(a-b) - c(a-b)(a+b)(a^2 + b^2) + ab(a-b)(a^2 + ab + b^2)}{6(b-a)(c-a)(b-c)} = \\
&= \frac{-c^4 + c(a+b)(a^2 + b^2) - ab(a^2 + ab + b^2)}{6(c-a)(b-c)} = \\
&= \frac{-c^4 + c(a^3 + ab^2 + a^2b + b^3) - (a^3b + a^2b^2 + ab^3)}{6(c-a)(b-c)} = \\
&= \frac{-c^4 + a^3c + ab^2c + a^2bc + b^3c - a^3b - a^2b^2 - ab^3}{6(c-a)(b-c)} = \\
&= \frac{-c(c-a)(c^2 + ac + a^2) + b^3(c-a) + ab^2(c-a) + a^2b(c-a)}{6(c-a)(b-c)} = \\
&= \frac{-c(c^2 + ac + a^2) + b^3 + ab^2 + a^2b}{6(b-c)} =
\end{aligned}$$

$$\begin{aligned}
& \frac{-c^3 - ac^2 - a^2c + b^3 + ab^2 + a^2b}{6(b-c)} = \\
& \frac{-(c-b)(c^2 + cb + b^2) - a(c-b)(c+b) - a^2(c-b)}{6(b-c)} = \\
& \frac{a^2 + b^2 + c^2 + ab + ac + bc}{6}
\end{aligned}$$

Una vez hemos obtenido la expresión simplificada para $E(X^2)$, podemos calcular la varianza, sustituyendo:

$$\begin{aligned}
\sigma_X^2 = V(X) &= E(X^2) - \mu_X^2 = \frac{a^2 + b^2 + c^2 + ab + ac + bc}{6} - \frac{(a+b+c)^2}{9} = \\
& \frac{a^2 + b^2 + c^2 + ab + ac + bc}{6} - \frac{a^2 + b^2 + c^2 + 2ab + 2ac + 2bc}{9} = \\
& \frac{3(a^2 + b^2 + c^2 + ab + ac + bc) - 2(a^2 + b^2 + c^2 + 2ab + 2ac + 2bc)}{18} = \\
& \frac{a^2 + b^2 + c^2 - ab - ac - bc}{18}
\end{aligned}$$

como se quería probar, siendo el resultado equivalente al encontrado en la ayuda.

- III) Para encontrar la expresión $X = F^{-1}(U)$ aplicamos el método de la inversa a la función de distribución calculada en el apartado anterior. Esta función inversa o $ppf(u)$ toma como input la probabilidad que da la función de distribución y nos devuelve el correspondiente valor de x . Al igual que hicimos con la función de distribución dividimos el triángulo en 2 trozos separados por el vértice c que es la moda, es decir, donde se divide el 50 % del área a cada lado. Dado que se trata de un triángulo equilátero, la probabilidad acumulada en c será de 0.5.

Dado que los parámetros son $a = 1$, $b = 5$ y $c = 3$, el denominador común en ambas ramas es $(b-a)(c-a) = 4 \cdot 2 = 8$ y $(b-a)(b-c) = 4 \cdot 2 = 8$.

Para el primer tramo ($0 \leq U \leq 0.5$):

$$U = \frac{(x-1)^2}{8} \implies 8U = (x-1)^2 \implies x = 1 + \sqrt{8U}$$

Para el segundo tramo ($0.5 \leq U \leq 1$):

$$U = 1 - \frac{(5-x)^2}{8} \implies \frac{(5-x)^2}{8} = 1 - U \implies x = 5 - \sqrt{8(1-U)}$$

La expresión final de la inversa es:

$$X = F^{-1}(U) = \begin{cases} 1 + \sqrt{8U} & \text{si } 0 \leq U \leq 0.5 \\ 5 - \sqrt{8(1-U)} & \text{si } 0.5 < U \leq 1 \end{cases}$$

A continuación, generaremos 10.000 simulaciones de esta función inversa. Para ello generaremos números aleatorios de una $U \sim (0, 1)$ (probabilidades acumuladas) y al aplicar la inversa $F^{-1}(u)$, estas respetarán nuestra función de distribución original.

Para cada número aleatorio u_i , si este está por debajo de 0.5 se le aplicará la expresión del primer tramo y si está por encima la del segundo.

Simulando 10.000 uniformes en Python y representando las X en un histograma nos queda una distribución tal que se reproduce la $pdf(x)$ triangular:




Figura 1: Simulación 10.000 uniformes por Montecarlo

Exercise 3

Consider the random variables of stock returns R_1 and R_2 with bivariate pdf:

$$f(r_1, r_2) = \begin{cases} \alpha + \beta r_1 + \gamma r_2, & -1 \leq r_1 \leq 2, \quad -2 \leq r_2 \leq 2.5 \\ 0, & \text{elsewhere} \end{cases} \quad (\text{I})$$

where $\alpha = 0.0642$, $\beta = 0.0049$, $\gamma = 0.0296$. Given some results from the problem set with title "Introduction to bivariate copulas", answer the questions:

- I) Find $E(R_1 | R_1 \leq F_1^{-1}(p))$ with $p = 0.01$ (Expected Shortfall). Obtain the conditional expectation $E(R_1 | R_2 = r_2) = \int_{-1}^2 r_1 f(r_1 | r_2) dr_1$, and also plot its graph.
- II) Obtain $C^1(u_1 | u_2)$, which is the conditional copula $C(u_1 | u_2) = P(U_1 \leq u_1 | U_2 = u_2)$ from the bivariate pdf (I).
- III) Generate $N = 10,000$ draws $\{(v_{1,k}, v_{2,k})\}_{k=1}^N$ of independent $V_i \sim U(0, 1)$ where $i = 1, 2$ to obtain N draws $\{(u_{1,k}, u_{2,k})\}_{k=1}^N$ of dependent $U_i \sim U(0, 1)$ such that $v_{1,k} = C^1(u_{1,k} | v_{2,k})$ in the previous section and $u_{2,k} = v_{2,k}$. Make the scatterplots for the simulated independent and dependent $U(0, 1)$ points.
- IV) Use the conditional sampling for draws of (R_1, R_2) with bivariate pdf (I) to generate N draws of (R_1, R_2) by changing the implied marginal distribution with $R_i \sim Tr(a_i, b_i, c_i)$ in Exercise 2, such that:
 - For R_1 : set $a_1 = -1$, $b_1 = 2$ and $c_1 = 3\mu_1 - b_1 - a_1$ with $\mu_1 = 0.55$.
 - For R_2 : set $a_2 = -2$, $b_2 = 2.5$ and $c_2 = 3\mu_2 - b_2 - a_2$ with $\mu_2 = 0.93$.

Compute both the sample mean and standard deviation of Portfolio **A** returns, containing 25 % of stock 1 and 75 % of stock 2 under the above procedure, and also the VaR values at 1 % and 5 %.

- V) Plot the histogram of the simulated returns of Portfolio **A** joint with the Normal distribution fit (you can use `histfit` function in Python), and compare with the `histfit` by running the Python program "bivaMC.m" to build Portfolio **B** returns, which are the simulated ones with the same weights as in Portfolio **A** under the bivariate pdf (I). Use a QQ-plot for the comparison of the quantiles of Portfolio **A** returns against Portfolio **B** returns. Obtain the same QQ-plot but considering now standardized Portfolio **A** and **B** returns.
Hint: Given program "bivaMC.m", it can be easily adapted to set $R_i \sim Tr(a_i, b_i, c_i)$ as new marginal distribution.

Resolución:

- I) Calcular un Expected Shortfall (la media de las pérdidas cuando exceden el VaR) es lo mismo que calcular la esperanza de una variable aleatoria truncada.

Para ello, partimos de la función de densidad conjunta bivalente del enunciado $f(r_1, r_2) = \alpha + \beta r_1 + \gamma r_2$ para obtener las funciones de densidades marginales de r_1 y r_2 integrando la conjunta con respecto a la otra variable en cada uno de sus respectivos límites de su dominio.

La marginal de R_1 es:

$$f_1(r_1) = \int_{-2}^{2.5} (\alpha + \beta r_1 + \gamma r_2) dr_2 = 4.5\alpha + 1.125\gamma + 4.5\beta r_1$$

La marginal de R_2 es:

$$f_2(r_2) = \int_{-1}^2 (\alpha + \beta r_1 + \gamma r_2) dr_1 = 3\alpha + 1.5\beta + 3\gamma r_2$$

Sustituyendo los valores de los parámetros del enunciado nos queda:

$$f_1(r_1) = 0.3222 + 0.02205r_1 \quad \text{para } -1 \leq r_1 \leq 2$$

$$f_2(r_2) = 0.20 + 0.0888r_2 \quad \text{para } -2 \leq r_2 \leq 2.5$$

El Expected Shortfall al 99 % ($p = 0.01$) se define como la media de las pérdidas en el peor 1 % de los casos, es decir, cuando las pérdidas exceden el VaR al 1 % $E(R_1 | R_1 \leq F_1^{-1}(p))$. Para hallarlo, primero debemos calcular cuánto vale este VaR.

Comenzamos obteniendo la expresión de la Función de Distribución Acumulada (CDF) integrando la densidad marginal:

$$F_1(x) = \int_{-1}^x f_1(u) du = \int_{-1}^x (0.3222 + 0.02205u) du$$

Resolvemos la integral y simplificamos la expresión:

$$\begin{aligned} F_1(x) &= \left[0.3222u + \frac{0.02205}{2}u^2 \right]_{-1}^x \\ &= (0.3222x + 0.011025x^2) - (0.3222(-1) + 0.011025(-1)^2) \\ &= 0.011025x^2 + 0.3222x - (-0.3222 + 0.011025) \\ &= 0.011025x^2 + 0.3222x + 0.311175 \end{aligned}$$

Para calcular el VaR (q), igualamos la función de distribución acumulada a la pro-

babilidad ($p = 0.01$) y reordenamos la expresión para obtener $ax^2 + bx + c = 0$:

$$0.011025q^2 + 0.3222q + 0.311175 = 0.01$$

$$0.011025q^2 + 0.3222q + 0.301175 = 0$$

Resolvemos la ecuación de 2º grado:

$$q = \frac{-0.3222 \pm \sqrt{0.3222^2 - 4(0.011025)(0.301175)}}{2(0.011025)}$$

Donde las soluciones son:

$$q_1 = -0.9669 \quad \text{y} \quad q_2 = -28.257$$

Analizamos las soluciones respecto al dominio de definición de la variable R_1 , que es $[-1, 2]$:

- La solución $q_2 = -28.257$ se descarta por estar fuera del dominio.
- La solución $q_1 = -0.9669$ se encuentra dentro del intervalo.

Por tanto, el VaR al 1 % es:

$$\boxed{\text{VaR}_{1\%} = q = -0.9669}$$

Vemos cómo la cota inferior del dominio de r_1 es -1 por lo que tiene sentido el valor de este cuantil.

Una vez obtenido el VaR ($q = -0.9669$), calculamos el Expected Shortfall (ES) al 99 % resolviendo la esperanza condicional de la cola de pérdidas (y ponderando por la probabilidad p):

$$\begin{aligned}
ES_{99\%} &= \frac{1}{p} \int_{-1}^q u \cdot f_1(u) du \\
&= \frac{1}{0.01} \int_{-1}^{-0.9669} u \cdot (0.3222 + 0.02205u) du \\
&= 100 \int_{-1}^{-0.9669} (0.3222u + 0.02205u^2) du \\
&= 100 \left[\frac{0.3222}{2} u^2 + \frac{0.02205}{3} u^3 \right]_{-1}^{-0.9669} \\
&= 100 [0.1611u^2 + 0.00735u^3]_{-1}^{-0.9669} \\
&= 100 [(0.1611(-0.9669)^2 + 0.00735(-0.9669)^3) - (0.1611(-1)^2 + 0.00735(-1)^3)] \\
&= 100(0.1440 - 0.15375) \\
&= 100(-0.00975) \\
&= -0.975
\end{aligned}$$

Por tanto,

$$ES_{99\%} = -0.975$$

Una vez calculado el ES, procedemos a la segunda parte del apartado i): obtener la Esperanza Condicional $E(R_1|R_2 = r_2)$. Esta medida nos indica el valor esperado del activo 1 dada una rentabilidad concreta de $R_2 = r_2$.

$$E(R_1|R_2 = r_2) = \int_{-1}^2 r_1 f(r_1|r_2) dr_1 = \int_{-1}^2 r_1 \frac{f(r_1, r_2)}{f_2(r_2)} dr_1$$

Dado que la marginal $f_2(r_2)$ actúa como constante respecto a la variable de integración r_1 la podemos sacar fuera de la integral:

$$\begin{aligned}
E(R_1|R_2 = r_2) &= \frac{1}{f_2(r_2)} \int_{-1}^2 (\alpha r_1 + \beta r_1^2 + \gamma r_1 r_2) dr_1 \\
&= \frac{1}{f_2(r_2)} \left[\frac{\alpha r_1^2}{2} + \frac{\beta r_1^3}{3} + \frac{\gamma r_2 r_1^2}{2} \right]_{-1}^2 \\
&= \frac{1}{f_2(r_2)} \left(\frac{\alpha}{2}(2^2 - (-1)^2) + \frac{\beta}{3}(2^3 - (-1)^3) + \frac{\gamma r_2}{2}(2^2 - (-1)^2) \right) \\
&= \frac{1.5\alpha + 3\beta + 1.5\gamma r_2}{3\alpha + 1.5\beta + 3\gamma r_2}
\end{aligned}$$

Finalmente, sustituimos los parámetros numéricos ($\alpha = 0.0642, \beta = 0.0049, \gamma = 0.0296$) para obtener la expresión final:

$$E(R_1|R_2 = r_2) = \frac{0.111 + 0.0444r_2}{0.20 + 0.0888r_2}$$




Figura 2: Esperanza del Activo 1 condicionada al Activo 2

- II) Necesitamos obtener la expresión analítica de la cópula condicional $C(u_1|u_2) = P(U_1 \leq u_1|U_2 = u_2)$.

Para llegar a esta expresión, utilizamos el Teorema de Sklar y la relación entre las variables uniformes y las variables originales a través de sus funciones de distribución

marginales:

$$u_1 = F_1(r_1) \iff r_1 = F_1^{-1}(u_1) \quad \text{y} \quad u_2 = F_2(r_2) \iff r_2 = F_2^{-1}(u_2)$$

La cópula condicional es equivalente a la distribución condicional de los retornos evaluada en las inversas:

$$C(u_1|u_2) = F(F_1^{-1}(u_1) | F_2^{-1}(u_2))$$

Primero derivamos la función de distribución de r_1 condicionada a un valor fijo de r_2 . Partimos de la densidad condicional, definida como $f(r_1|r_2) = \frac{f(r_1, r_2)}{f_2(r_2)}$.

Para obtener la acumulada, integramos la densidad condicional respecto a r_1 , tratando r_2 como constante:

$$\begin{aligned} F(r_1|r_2) &= \int_{-1}^{r_1} f(x|r_2)dx = \frac{1}{f_2(r_2)} \int_{-1}^{r_1} (\alpha + \beta x + \gamma r_2)dx \\ &= \frac{1}{f_2(r_2)} \left[\alpha x + \frac{\beta x^2}{2} + \gamma r_2 x \right]_{-1}^{r_1} \\ &= \frac{1}{f_2(r_2)} \left[\left(\alpha r_1 + \frac{\beta r_1^2}{2} + \gamma r_1 r_2 \right) - \left(-\alpha + \frac{\beta}{2} - \gamma r_2 \right) \right] \\ &= \frac{1}{f_2(r_2)} \left[\alpha(r_1 + 1) + \frac{\beta}{2}(r_1^2 - 1) + \gamma r_2(r_1 + 1) \right] \\ &= \frac{(r_1 + 1)}{f_2(r_2)} \left[\alpha + \frac{\beta}{2}(r_1 - 1) + \gamma r_2 \right] \end{aligned}$$

Sustituyendo r_1 y r_2 por sus expresiones inversas $F_1^{-1}(u_1)$ y $F_2^{-1}(u_2)$, obtenemos la fórmula cerrada de la cópula:

$$\boxed{C(u_1|u_2) = \frac{(F_1^{-1}(u_1) + 1)}{f_2(F_2^{-1}(u_2))} \left[\alpha + \frac{\beta}{2}(F_1^{-1}(u_1) - 1) + \gamma F_2^{-1}(u_2) \right]}$$

La expresión de $F_1^{-1}(u_1)$ la podemos obtener como hemos efectuado en el primer apartado para el cálculo del VaR:

$$F_1(x) = u_1 = 0.011025x^2 + 0.3222x + 0.311175 \Rightarrow$$

$$F_1^{-1}(u_1) = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1)}}{2(0.011025)}.$$

Para obtener $F_2^{-1}(u_2)$, primero obtendremos la cdf para R_2 :

$$F_2(x) = \left[0.2u + \frac{0.0888}{2}u^2 \right]_{-2}^x$$

$$= (0.2x + 0.0444x^2) - (0.2(-2) + 0.0444(-2)^2)$$

$$= 0.0444x^2 + 0.2x - (-0.4 + 0.1776)$$

$$= 0.0444x^2 + 0.2x + 0.222.$$

Así, la expresión para $F_2^{-1}(u_2)$ sería:

$$F_2(x) = u_2 = 0.0444x^2 + 0.2x + 0.222 \Rightarrow$$

$$F_2^{-1}(u_2) = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2)}}{2(0.0444)}.$$

Nota: Nos quedamos con la raíz positiva para obtener las inversas de las cdf para asegurar que el valor caiga dentro del dominio. De este modo, obtenemos la fórmula de la cópula, en la que no necesitamos la función de distribución bivalente condicional para realizar el “conditional” sampling:

- III) Necesitamos generar $N = 10,000$ simulaciones de pares dependientes (u_1, u_2) utilizando el “conditional sampling”. Una vez obtenida la cópula, podemos trabajar con ella y establecer la dependencia entre ambas variables aleatorias inferida por la distribución bivalente, sin necesidad de conocerla, simplemente conociendo las cdf marginales de cada variable (y su inversa, como hemos deducido en el apartado anterior).

Como podemos comprobar, observando el resultado del apartado anterior y la ecuación de las inversas de las cdf marginales, la generación de números uniformes dependientes mediante la cópula es bastante tedioso, debido a la complejidad de su fórmula. Aprovechándonos de que es equivalente, tanto el método como el resultado, para generar valores dependientes usando la cópula (útil cuando desconocemos la distribución multivalente entre las variables) como usando la distribución condicional de las variables aleatorias, como conocemos esta última, obtendremos los valores dependientes mediante este método, por simplicidad computacional.

Para generar cada par de variables dependientes (r_1, r_2) que respeten la estructura de la cópula, seguimos el siguiente procedimiento iterativo:

- a) Generamos dos números aleatorios uniformes independientes: $v_1 \sim U(0, 1)$ y $v_2 \sim U(0, 1)$.
- b) Calculamos el valor de la segunda variable usando su inversa marginal con el segundo aleatorio:

$$r_2^* = F_2^{-1}(v_2)$$

- c) Para obtener r_1 , debemos resolver la ecuación que iguala la distribución condicional al primer aleatorio uniforme v_1 :

$$F_1(r_1|r_2^*) = v_1 \Rightarrow r_1^* = F_1^{-1}(v_1|r_2 = r_2^*)$$

Haciendo uso de la estructura de cópula (lo introducimos para ilustrar el proceso, aunque es equivalente):

- a) Generamos dos números aleatorios uniformes independientes: $v_1 \sim U(0, 1)$ y $v_2 \sim U(0, 1)$.
- b) Nuestro primer valor aleatorio dependiente es igual al primer valor aleatorio obtenido previamente: $u_2^* = v_2$
- c) Para obtener u_1^* , debemos resolver la ecuación que iguala la distribución condicional al primer aleatorio uniforme v_1 :

$$C(u_1|u_2^*) = v_1 \Rightarrow u_1^* = C^{-1}(v_1|u_2 = u_2^*)$$

Este procedimiento implementa la lógica del programa “bivaMC.m” facilitado en el material del curso, adaptándolo para guardar los vectores de uniformes dependientes.

Sustituyendo la expresión derivada en el apartado (ii), llegamos a la ecuación cua-

drática fundamental para la simulación:

$$\begin{aligned}
 F(r_1|r_2) &= v_1 \\
 \frac{(r_1 + 1)}{f_2(r_2)} \left[\alpha + \frac{\beta}{2}(r_1 - 1) + \gamma r_2 \right] &= v_1 \\
 (r_1 + 1) \left[\alpha + \gamma r_2 + \frac{\beta}{2}(r_1 - 1) \right] &= v_1 \cdot f_2(r_2) \\
 (r_1 + 1)(\alpha + \gamma r_2) + (r_1 + 1)\frac{\beta}{2}(r_1 - 1) &= v_1 \cdot f_2(r_2) \\
 r_1(\alpha + \gamma r_2) + (\alpha + \gamma r_2) + \frac{\beta}{2}(r_1^2 - 1) &= v_1 \cdot f_2(r_2) \\
 (\alpha + \gamma r_2)r_1 + \alpha + \gamma r_2 + \frac{\beta}{2}r_1^2 - \frac{\beta}{2} &= v_1 \cdot f_2(r_2) \\
 \frac{\beta}{2}r_1^2 + (\alpha + \gamma r_2)r_1 + \left(\alpha + \gamma r_2 - \frac{\beta}{2} \right) &= v_1 \cdot f_2(r_2) \\
 \frac{\beta}{2}r_1^2 + (\alpha + \gamma r_2)r_1 + \left[\alpha - \frac{\beta}{2} + \gamma r_2 - v_1 \cdot f_2(r_2) \right] &= 0
 \end{aligned}$$

Donde $f_2(r_2) = 0.20 + 0.0888r_2$. Para cada simulación, resolvemos esta ecuación para r_1 y seleccionamos la raíz que satisface la restricción del dominio $-1 \leq r_1 \leq 2$.

Finalmente, para obtener las uniformes dependientes (u) que usaremos en el siguiente apartado, calculamos:

$$u_1 = F_1(r_1) \quad \text{y} \quad u_2 = F_2(r_2) \quad (\text{donde } u_2 \equiv v_2)$$

Exercise 3: Conditional Sampling Simulation




Figura 3: Conditional Sampling Simulation

Son muy parecidos los gráficos, debido a que estas variables tienen una correlación muy baja:

$$\mu_1 = E(r_1) = \int_{-1}^2 r_1 f_1(r_1) dr_1 = \int_{-1}^2 (0.3222r_1 + 0.0222r_1^2) dr_1 = 0.55$$

$$\mu_2 = E(r_2) = \int_{-2}^{2.5} r_2 f_2(r_2) dr_2 = \int_{-2}^{2.5} (0.2r_2 + 0.0888r_2^2) dr_2 = 0.92$$

$$\sigma_1^2 = \int_{-1}^2 r_1^2 f_1(r_1) dr_1 - \mu_1^2 = 1.04985 - 0.55^2 = 0.75$$

$$\sigma_2^2 = \int_{-2}^{2.5} r_2^2 f_2(r_2) dr_2 - \mu_2^2 = 2.264588 - 0.92^2 = 1.42$$

$$Cov(R_1, R_2) = E(r_1 r_2) - \mu_1 \mu_2 =$$

$$\int_{-1}^2 \int_{-2}^{2.5} r_1 r_2 f(r_1, r_2) dr_1 dr_2 - 0.55 \cdot 0.92 =$$

$$\int_{-1}^2 dr_1 \int_{-2}^{2.5} (\alpha r_1 r_2 + \beta r_1^2 r_2 + \gamma r_1 r_2^2) dr_2 - 0.55 \cdot 0.92 = 0.4752 - 0.55 \cdot 0.92 = -0.0308$$

Para ver la correlación, se ve:

$$\rho = \frac{\sigma_{12}}{\sigma_1 \sigma_2} = \frac{-0.0308}{\sqrt{0.75} \sqrt{1.42}} = -0.03$$

que es cercana a 0, de ahí la similitud de los gráficos.

- IV) Para aplicar la cópula a unas nuevas distribuciones marginales triangulares obtenidas en el ejercicio 2, primero obtenemos los parámetros c de estas distribuciones $R_i \sim Tr(a_i, b_i, c_i)$. Aplicando el Teorema de Sklar, podemos conservar la estructura de dependencia (las cópulas) pero cambiando las marginales (Frankenstein).

Dado que la media de una distribución triangular es $\mu = \frac{a+b+c}{3}$, despejamos el parámetro c como $c = 3\mu - a - b$.

Dados $a_1 = -1, b_1 = 2, \mu_1 = 0.55$:

$$c_1 = 3(0.55) - (-1) - 2 = 1.65 + 1 - 2 = 0.65$$

Dados $a_2 = -2, b_2 = 2.5, \mu_2 = 0.93$:

$$c_2 = 3(0.93) - (-2) - 2.5 = 2.79 + 2 - 2.5 = 2.29$$

Para generar los nuevos rendimientos (R_1^{Tr}, R_2^{Tr}) , utilizamos los pares de uniformes dependientes $(u_{1,k}, u_{2,k})$ generados en el apartado (iii). Estas uniformes capturan la dependencia original y la transfieren a las nuevas distribuciones mediante la función

inversa (*ppf*).

Antes de aplicar la fórmula, derivamos la función inversa partiendo de la Función de Distribución Acumulada (CDF), la cual obtenemos integrando la densidad triangular por tramos:

- **Tramo de subida:** Integramos desde a hasta x :

$$F(x) = \int_a^x \frac{2(t-a)}{(b-a)(c-a)} dt = \frac{(x-a)^2}{(b-a)(c-a)}$$

Igualando a u y despejando x :

$$u = \frac{(x-a)^2}{(b-a)(c-a)} \implies x = a + \sqrt{u(b-a)(c-a)}$$

- **Tramo de bajada:** Integramos usando el complementario desde x hasta b :

$$F(x) = 1 - \int_x^b \frac{2(b-t)}{(b-a)(b-c)} dt = 1 - \frac{(b-x)^2}{(b-a)(b-c)}$$

Igualando a u y despejando x :

$$u = 1 - \frac{(b-x)^2}{(b-a)(b-c)} \implies x = b - \sqrt{(1-u)(b-a)(b-c)}$$

Por tanto, la inversa de una variable $X \sim Tr(a, b, c)$ para un cuantil $u \in [0, 1]$ queda definida formalmente por tramos, siendo el punto de corte $F(c) = \frac{c-a}{b-a}$:

$$F^{-1}(u) = \begin{cases} a + \sqrt{u(b-a)(c-a)} & \text{si } u \leq \frac{c-a}{b-a} \\ b - \sqrt{(1-u)(b-a)(b-c)} & \text{si } u > \frac{c-a}{b-a} \end{cases} \quad (1)$$

Aplicamos esta transformación a cada activo con sus respectivos parámetros:

- Generar R_1 :** Usamos el vector de uniformes dependientes u_1 (obtenido como $F_1(r_1)$ en el apartado anterior) y aplicamos $F_{Tr}^{-1}(u_1)$ con parámetros $(-1, 2, 0.65)$.
- Generar R_2 :** Usamos el vector de uniformes dependientes u_2 (que coincide con v_2) y aplicamos $F_{Tr}^{-1}(u_2)$ con parámetros $(-2, 2.5, 2.29)$.

Este proceso garantiza que las marginales sean Triangulares mientras que la estructura de dependencia entre R_1 y R_2 se mantiene idéntica a la de la función de densidad conjunta original.

Una vez obtenidos los vectores de retornos simulados con marginales triangulares R_1^{Tr} y R_2^{Tr} , construimos la cartera ponderada punto a punto para cada simulación

$i = 1, \dots, 10.000$:

$$R_{p,i}^A = 0.25 \cdot R_{1,i}^{Tr} + 0.75 \cdot R_{2,i}^{Tr} \quad (2)$$

Sobre los rendimientos de esta cartera simulamos de 10.000 escenarios y calculamos la media, la desviación típica y el VaR:

- **Media:** $\hat{\mu}_p^A = \frac{1}{N} \sum R_{p,i}^A$
- **Desviación Típica:** $\hat{\sigma}_p^A = \sqrt{\frac{1}{N-1} \sum (R_{p,i}^A - \hat{\mu}_p^A)^2}$
- **VaR Histórico:** Corresponde a los cuantiles al 1 % y 5 % de la distribución simulada.

Tras realizar las 10,000 simulaciones en Python, los resultados son:

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^A$)	0.8391
Desviación Típica ($\hat{\sigma}_p^A$)	0.7880
VaR ^A 1 %	-1.0351
VaR ^A 5 %	-0.6129

Tabla 1: Estadísticos descriptivos y VaR de la Cartera **A**

v) A continuación se adjuntan los gráficos requeridos del enunciado generados en Python.






Figura 4: Histograma de la Cartera **A**

Figura 5: QQ-Plot: A vs B Figura 6: QQ-Plot: A vs B (Estandarizado)

Exercise 4

Consider the random variables of stock returns R_1 and R_2 with bivariate pdf given by $f(r_1, r_2) = c(F_1(r_1), F_2(r_2))f_1(r_1)f_2(r_2)$ such that the marginal distributions are those from the bivariate pdf (I). Obtain $f(r_1, r_2)$ under alternative bivariate copulas in the following cases:

- i) The bivariate standardized Gaussian (G) copula pdf with ρ as the correlation coefficient is given by:

$$c^G(u_1, u_2; \rho) = |\Psi|^{-1/2} \exp\left(-\frac{1}{2}\eta'(\Psi^{-1} - I_2)\eta\right)$$

where $\eta = (\Phi^{-1}(u_1), \Phi^{-1}(u_2))'$, Ψ is the correlation matrix, I_2 is the identity matrix of order 2, and $\Phi^{-1}(\bullet)$ is the inverse of the $N(0, 1)$ cdf.

- ii) The bivariate FGM copula pdf is given by:

$$c^{FGM}(u_1, u_2; \lambda) = 1 + \lambda(2u_1 - 1)(2u_2 - 1)$$

where $\lambda \in [-1, 1]$.

Resolución:

En este ejercicio vamos a aplicar el Teorema de Sklar para construir densidades conjuntas. Para ello, cogemos las marginales $f_1(r_1)$ y $f_2(r_2)$ que ya calculamos antes y las unimos usando una cópula $c(u_1, u_2)$ para sacar una nueva densidad conjunta $f(r_1, r_2)$.

$$f(r_1, r_2) = c(F_1(r_1), F_2(r_2)) \cdot f_1(r_1) \cdot f_2(r_2)$$

En la Cópula Gaussiana la dependencia funciona igual que en una Normal bivalente y viene dada por el parámetro de la correlación ρ . La fórmula de la densidad de la cópula es:

$$c^G(u_1, u_2; \rho) = \frac{1}{\sqrt{1 - \rho^2}} \exp\left(-\frac{\eta'(\Psi^{-1} - I_2)\eta}{2}\right)$$

Aquí Ψ es la matriz de correlación y el vector η son las inversas de la normal $N(0, 1)$. Para no complicar la notación, llamamos $x_1 = \Phi^{-1}(F_1(r_1))$ y $x_2 = \Phi^{-1}(F_2(r_2))$. Si sustituimos en la fórmula de arriba, la densidad conjunta nos queda:

$$f(r_1, r_2) = \frac{1}{\sqrt{1 - \rho^2}} \exp\left(-\frac{x_1^2 + x_2^2 - 2\rho x_1 x_2}{2(1 - \rho^2)} + \frac{x_1^2 + x_2^2}{2}\right) \cdot f_1(r_1) \cdot f_2(r_2)$$

donde x_1, x_2 son las funciones inversas de la normal evaluadas en la función de distribución

y $f_1(r_1)$, $f_2(r_2)$ son las densidades marginales que obtuvimos en el ejercicio anterior:

$$x_1 = \Phi^{-1}(0.011025r_1^2 + 0.3222r_1 + 0.311175)$$

$$x_2 = \Phi^{-1}(0.0444r_2^2 + 0.20r_2 + 0.2224)$$

$$f_1(r_1) = 0.3222 + 0.02205r_1$$

$$f_2(r_2) = 0.20 + 0.0888r_2$$

Con esta función de densidad conjunta se mantienen nuestras marginales originales (rectas f_1 y f_2) y además conservan una estructura de dependencia Normal.

Por otro lado, la Cópula FGM es útil para dependencias más suaves y depende del parámetro λ . La expresión de su densidad es más sencilla: $c^{FGM}(u_1, u_2; \lambda) = 1 + \lambda(1 - 2u_1)(1 - 2u_2)$. Aplicando Sklar de nuevo (multiplicando la cópula por las marginales), la expresión general nos queda:

$$f(r_1, r_2) = [1 + \lambda(1 - 2F_1(r_1))(1 - 2F_2(r_2))] \cdot f_1(r_1) \cdot f_2(r_2)$$

Para dejarlo todo expresado en función de r_1 y r_2 sustituimos todo en la ecuación y llegamos a la expresión final desarrollada:

$$\begin{aligned} f(r_1, r_2) = & \left(1 + \lambda \left[1 - 2(0.011025r_1^2 + 0.3222r_1 + 0.311175) \right] \right) \\ & \cdot \left[1 - 2(0.0444r_2^2 + 0.20r_2 + 0.2224) \right] \\ & \cdot (0.3222 + 0.02205r_1) \cdot (0.20 + 0.0888r_2) \end{aligned}$$

Exercise 5

Consider the bivariate FGM copula cdf given by $C^{FGM}(u_1, u_2; \lambda) = u_1 u_2 [1 + \lambda(1 - u_1)(1 - u_2)]$ where $\lambda \in [-1, 1]$. Check that the following results are verified:

- I) $\frac{\partial^2 C^{FGM}(u_1, u_2; \lambda)}{\partial u_1 \partial u_2}$ is equal to the FGM copula pdf in section ii) in Exercise 4.
 - II) $E(U_1 | U_2 = u_2)$ is linear in u_2 .
 - III) $C^{FGM}(u_i | u_j) = u_i [1 + \lambda(1 - u_i)(1 - 2u_j)]$.
- Hint:* $C(u_i | u_j) = P(U_i \leq u_i | U_j = u_j) = \frac{\partial C(u_1, u_2)}{\partial u_j}, i, j \in \{1, 2\}; i \neq j$.

Resolución:

En este ejercicio trataremos de demostrar las propiedades de la cópula FGM a partir de la función de distribución (CDF) y calculando sus derivadas.

Para simplificar las derivadas, comenzamos expandiendo algebraicamente la expresión de la CDF:

$$\begin{aligned} C(u_1, u_2) &= u_1 u_2 [1 + \lambda(1 - u_1)(1 - u_2)] \\ &= u_1 u_2 + \lambda u_1 u_2 (1 - u_1 - u_2 + u_1 u_2) \\ &= u_1 u_2 + \lambda(u_1 u_2 - u_1^2 u_2 - u_1 u_2^2 + u_1^2 u_2^2) \end{aligned}$$

- I) La densidad $c(u_1, u_2)$, tal y como se expresa en el enunciado se obtiene mediante la segunda derivada de la función de distribución, derivando primero con respecto a u_1 y luego respecto a u_2 :

$$\begin{aligned} \frac{\partial C}{\partial u_1} &= u_2 + \lambda(u_2 - 2u_1 u_2 - u_2^2 + 2u_1 u_2^2) \\ c(u_1, u_2) &= \frac{\partial^2 C}{\partial u_1 \partial u_2} = \frac{\partial}{\partial u_2} \left[\frac{\partial C}{\partial u_1} \right] = 1 + \lambda(1 - 2u_1 - 2u_2 + 4u_1 u_2) \end{aligned}$$

Podemos simplificar la expresión factorizando $(1 - 2u_1) - 2u_2(1 - 2u_1) = (1 - 2u_1)(1 - 2u_2)$:

$$c(u_1, u_2) = 1 + \lambda(1 - 2u_1)(1 - 2u_2)$$

Este resultado coincide exactamente con la densidad utilizada en el Ejercicio 4.

- II) El enunciado nos pide demostrar que $E[U_1 | U_2 = u_2]$ es una función lineal de u_2 . Dado que las marginales son uniformes $U \sim U(0, 1)$, su densidad marginal es igual a 1 ($f(u) = 1$). Entonces:

$$c(u_1 | u_2) = \frac{c(u_1, u_2)}{f_{U_2}(u_2)} = \frac{c(u_1, u_2)}{1} = c(u_1, u_2)$$

Sustituyendo esto en la expresión de la esperanza y separando los términos constantes:

$$\begin{aligned}
 E[U_1|U_2 = u_2] &= \int_0^1 u_1 \cdot c(u_1, u_2) du_1 \\
 &= \int_0^1 u_1 [1 + \lambda(1 - 2u_1)(1 - 2u_2)] du_1 \\
 &= \int_0^1 u_1 du_1 + \lambda(1 - 2u_2) \int_0^1 (u_1 - 2u_1^2) du_1
 \end{aligned}$$

Resolvemos las integrales:

$$\begin{aligned}
 \int_0^1 u_1 du_1 &= \left[\frac{u_1^2}{2} \right]_0^1 = \frac{1}{2} \\
 \int_0^1 (u_1 - 2u_1^2) du_1 &= \left[\frac{u_1^2}{2} - \frac{2u_1^3}{3} \right]_0^1 = \frac{1}{2} - \frac{2}{3} = -\frac{1}{6}
 \end{aligned}$$

Sustituyendo ambos resultados en la expresión general de la esperanza:

$$E[U_1|U_2 = u_2] = \frac{1}{2} + \lambda(1 - 2u_2) \left(-\frac{1}{6} \right) = \left(\frac{1}{2} - \frac{\lambda}{6} \right) + \left(\frac{\lambda}{3} \right) u_2$$

Observamos que la expresión resultante tiene la forma de una recta, demostrando que es lineal respecto a u_2 .

- III) La distribución condicional $C(u_i|u_j)$ se obtiene derivando la CDF respecto a la condición. Recuperamos la derivada parcial $\frac{\partial C}{\partial u_2}$:

$$\begin{aligned}
 C(u_1|u_2) &= \frac{\partial C}{\partial u_2} = u_1 + \lambda(u_1 - u_1^2 - 2u_1u_2 + 2u_1^2u_2) \\
 &= u_1[1 + \lambda(1 - u_1 - 2u_2 + 2u_1u_2)] \\
 &= u_1[1 + \lambda((1 - u_1) - 2u_2(1 - u_1))] \\
 &= u_1[1 + \lambda(1 - u_1)(1 - 2u_2)]
 \end{aligned}$$

La fórmula general por tanto es $C(u_i|u_j) = u_i[1 + \lambda(1 - u_i)(1 - 2u_j)]$.

Exercise 6

Given the results in Exercise 5 for the bivariate FGM copula, try to answer the following questions:

- I) Generate $N = 10,000$ draws $\{(v_{1,k}, v_{2,k})\}_{k=1}^N$ of independent $V_i \sim U(0, 1)$ where $i = 1, 2$ to obtain N draws $\{(u_{1,k}, u_{2,k})\}_{k=1}^N$ of dependent $U_i \sim U(0, 1)$ such that $v_{1,k} = C^{FGM}(u_{1,k}|v_{2,k})$ with $\lambda = 1/2$ and $u_{2,k} = v_{2,k}$. Make two scatterplots for the simulated independent and dependent $U(0, 1)$ points.
- II) Consider the marginal distributions of R_1 and R_2 from the bivariate pdf (I). Generate $N = 10,000$ draws of $(R_1, R_2) = (F_1^{-1}(U_1), F_2^{-1}(U_2))$ where (U_1, U_2) is a bivariate uniform obtained under the “conditional sampling” in section i) of this Exercise.

Compute the sample mean and standard deviation of the N simulated Portfolio $\mathbf{C}$ returns, containing 25 % of stock 1 and 75 % of stock 2 under the above procedure, and also the VaR values at 1 % and 5 %. Plot the histogram of the Portfolio $\mathbf{C}$ returns joint with the Normal distribution fit (you can use `histfit` function in Python).

Resolución:

- I) Como estamos haciendo en los demás ejercicios, para calcular las muestras dependientes, debemos seguir el siguiente esquema:
 - a) Generamos dos números aleatorios uniformes independientes: $v_1 \sim U(0, 1)$ y $v_2 \sim U(0, 1)$.
 - b) Nuestro primer valor aleatorio dependiente es igual al primer valor aleatorio obtenido previamente: $u_2^* = v_2$
 - c) Para obtener u_1^* , debemos resolver la ecuación que iguala la distribución condicional al primer aleatorio uniforme v_1 :

$$C^{FGM}(u_1|u_2^*) = v_1 \Rightarrow u_1^* = (C^{FGM})^{-1}(v_1|u_2 = u_2^*)$$

Como estamos considerando $\lambda = 1/2$ para la cópula FGM, se tiene la siguiente fórmula para u_1^* :

$$\begin{aligned} u_1^* [1 + 0.5 \cdot (1 - u_1^*)(1 - 2u_2^*)] &= v_1 \Rightarrow \\ (u_1^*)^2 (u_2^* - 0.5) + u_1^* (-u_2^* + 1.5) - v_1 &= 0 \Rightarrow (u_2^* \neq 0) \\ u_1^* &= \frac{(-1.5 + u_2^*) + \sqrt{(-u_2^* + 1.5)^2 + 4(u_2^* - 0.5)v_1}}{2(u_2^* - 0.5)} \end{aligned}$$

Aquí de nuevo, tomamos la raíz positiva, ya que necesitamos que esté dentro del dominio u_1^* .

Esta solución, evidentemente, es si $u_2^* \neq 0$, en caso de que $u_2^* = 0$, se tiene que $u_1^* = v_1$.




Figura 7: Conditional Sampling Simulation

De nuevo, obtenemos dos gráficos muy semejantes, ya que hemos podido comprobar que la correlación entre u_1 y u_2 es muy baja, del 0.17 aproximadamente, como hemos podido comprobar en nuestro código.

II) Recordemos las cdf marginales a las que el enunciado hace referencia:

a) Para $R_1 : u_1 = F_1(r_1) = 0.011025x^2 + 0.3222x + 0.311175$,

$$r_1^* = F_1^{-1}(u_1^*) = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1^*)}}{2(0.011025)}.$$

b) Para $R_2 : u_2 = F_2(r_2) = 0.0444x^2 + 0.2x + 0.222$,

$$r_2^* = F_2^{-1}(u_2^*) = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2^*)}}{2(0.0444)}.$$

Dados los valores obtenidos en el apartado anterior, sacamos los rendimientos con la dependencia de la cópula FGM deseados.

Para ahora obtener los momentos de la cartera $\mathbf{C}$, una vez tenemos las $i = 1, \dots, 10000$ simulaciones de los rendimientos $r_{1,i}^*$ y $r_{2,i}^*$, calculamos los rendimientos de la cartera como sigue:

$$r_{p,i}^C = 0.25 \cdot r_{1,i}^* + 0.75 \cdot r_{2,i}^*$$

- **Media:** $\hat{\mu}_p^C = \frac{1}{N} \sum r_{p,i}^C$
- **Desviación Típica:** $\hat{\sigma}_p^C = \sqrt{\frac{1}{N-1} \sum (r_{p,i}^C - \hat{\mu}_p^C)^2}$

- **VaR Histórico:** Corresponde a los cuantiles al 1 % y 5 % de la distribución simulada.

Tras realizar las 10.000 simulaciones en Python, los resultados son:

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^C$)	0.8223
Desviación Típica ($\hat{\sigma}_p^C$)	0.8960
VaR ^C 1 %	-1.2667
VaR ^C 5 %	-0.7994

Tabla 2: Estadísticos descriptivos y VaR de la Cartera C

Adjuntamos el histograma de la cartera C junto con la distribución normal, que es muy semejante al obtenido en el Ejercicio 3, lógicamente.




Figura 8: Histograma de la Cartera C

Exercise 7

Let (U_1, U_2) be a bivariate uniform generated from the G copula with $\rho = -0.7$ as correlation coefficient (standardized Gaussian copula), see section i) in Exercise 4. Repeat the same analysis as in Exercise 6 by obtaining $N = 10,000$ draws of (R_1, R_2) with marginal distributions of R_i from the bivariate pdf (I). The cdf of U_1 given $U_2 = u_2$ in the G copula (or conditional G copula) is obtained from the cdf of the G copula, $\Phi_2(\cdot)$, then

$$C^G(u_1|u_2) = \frac{\partial}{\partial u_2} \Phi_2(\Phi^{-1}(u_1), \Phi^{-1}(u_2)) = \Phi \left(\frac{\Phi^{-1}(u_1) - \rho \Phi^{-1}(u_2)}{\sqrt{1 - \rho^2}} \right),$$

where $\Phi(\cdot)$ and $\Phi^{-1}(\cdot)$ are, respectively, the $N(0, 1)$ cdf and its inverse. Obtain both the sample mean and standard deviation of the portfolio $\mathbf{D}$ returns, containing 25 % of stock 1 and 75 % of stock 2 under the above procedure, and also the VaR values at 1 % and 5 %.

Resolución:

Tenemos que seguir el siguiente esquema para generar los rendimientos aleatorios:

1. Generamos dos números aleatorios uniformes independientes: $v_1 \sim U(0, 1)$ y $v_2 \sim U(0, 1)$.
2. Nuestro primer valor aleatorio dependiente es igual al primer valor aleatorio obtenido previamente: $u_2^* = v_2$
3. Para obtener u_1^* , debemos resolver la ecuación que iguala la distribución condicional al primer aleatorio uniforme v_1 :

$$\begin{aligned} C^G(u_1|u_2^*) = v_1 &\Rightarrow \Phi \left(\frac{\Phi^{-1}(u_1^*) - \rho \Phi^{-1}(u_2^*)}{\sqrt{1 - \rho^2}} \right) = v_1 \Rightarrow \\ \Phi^{-1}(v_1) &= \frac{\Phi^{-1}(u_1^*) - \rho \Phi^{-1}(u_2^*)}{\sqrt{1 - \rho^2}} \Rightarrow \\ \Phi^{-1}(u_1^*) &= \Phi^{-1}(v_1) \sqrt{1 - \rho^2} + \rho \Phi^{-1}(u_2^*) \Rightarrow \\ u_1^* &= \Phi \left(\rho \Phi^{-1}(u_2^*) + \sqrt{1 - \rho^2} \Phi^{-1}(v_1) \right) \end{aligned}$$

Esta será la fórmula que le daremos a Python para generar los números uniformes dependientes.




Figura 9: Conditional Sampling Simulation

Como se puede comprobar, ahora sí que son muy diferentes los scatterplots, ya que hemos generado los uniformes con una mayor correlación que en los anteriores casos.

Una vez obtenidos, generaremos los rendimientos dependientes como hemos hecho en el ejercicio previo:

$$1. \quad r_1^* = F_1^{-1}(u_1^*) = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1^*)}}{2(0.011025)}.$$

$$2. \quad r_2^* = F_2^{-1}(u_2^*) = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2^*)}}{2(0.0444)}.$$

Para ahora obtener los momentos de la cartera D , una vez tenemos las $i = 1, \dots, 10000$ simulaciones de los rendimientos $r_{1,i}^*$ y $r_{2,i}^*$, calculamos los rendimientos de la cartera como sigue:


$$r_{p,i}^D = 0.25 \cdot r_{1,i}^* + 0.75 \cdot r_{2,i}^*$$

- **Media:** $\hat{\mu}_p^D = \frac{1}{N} \sum r_{p,i}^D$
- **Desviación Típica:** $\hat{\sigma}_p^D = \sqrt{\frac{1}{N-1} \sum (r_{p,i}^D - \hat{\mu}_p^D)^2}$
- **VaR Histórico:** Corresponde a los cuantiles al 1 % y 5 % de la distribución simulada.

Tras realizar las 10,000 simulaciones en Python, los resultados son los siguientes.

Adjuntamos el histograma de la cartera D junto con la distribución normal, donde observamos, como se comprueba en los estadísticos descriptivos anteriores, que parece que esta cartera con la dependencia descrita por la cópula tiene mejores resultados que las anteriores.

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^D$)	0.8387
Desviación Típica ($\hat{\sigma}_p^D$)	0.7009
VaR ^D 1 %	-0.8642
VaR ^D 5 %	-0.4928

Tabla 3: Estadísticos descriptivos y VaR de la Cartera **D**Figura 10: Histograma de la Cartera **D**

Exercise 8

According to Exercise 7, the q quantile curve under the G copula when the marginals are arbitrary distributions, with cdf's $F_i(\bullet)$ $i = 1, 2$, is given by $C^G(u_1|u_2) = q$, then $u_1 = \Phi(\rho\Phi^{-1}(u_2) + \sqrt{1-\rho^2}\Phi^{-1}(q))$ where $u_i = F_i(r_i)$.

Definitively:

$$r_1 = F_1^{-1} \left[\Phi \left(\rho\Phi^{-1}(F_2(r_2)) + \sqrt{1-\rho^2}\Phi^{-1}(q) \right) \right].$$

Consider as marginals those obtained from the bivariate pdf (I). Make a plot of the q quantile curves for $q = 0.05, 0.25, 0.5, 0.75, 0.95$.

Resolución:

Recordamos las cdf marginales que solicita el enunciado:

$$F_1(r_1) = u_1 = 0.011025r_1^2 + 0.3222r_1 + 0.311175$$

$$F_1^{-1}(u_1) = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1)}}{2(0.011025)}$$

$$F_2(r_2) = u_2 = 0.0444r_2^2 + 0.2r_2 + 0.222$$

$$F_2^{-1}(u_2) = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2)}}{2(0.0444)}$$

Para generar las curvas de los cuantiles q , lo que haremos será generar números aleatorios uniformes $u_2 = F(r_2)$ y a partir de estos emplearemos la fórmula del enunciado para generar los gráficos solicitados.




Figura 11: Curvas de cuantil G cópula

Exercise 9

Repeat Exercise 8 where $u_i = \Phi(r_i)$ $i = 1, 2$, then $r_1 = \rho r_2 + \sqrt{1 - \rho^2} \Phi^{-1}(q)$. Make again a plot of the q quantile curves for $q = 0.05, 0.25, 0.5, 0.75, 0.95$.

Resolución:

En este caso, generaremos los números aleatorios u_2 uniformes, de estos obtendremos los rendimientos $r_2 = \Phi^{-1}(u_2)$ y a partir de ellos los rendimientos correlados con la fórmula del enunciado. Cabe destacar que la relación entre ambos rendimientos es lineal por lo que esperaremos líneas rectas como curvas de cuantiles, con pendiente igual a la correlación (-0.7) empleada.




Figura 12: Curvas de cuantil uniformes

Exercise 10

The cdf of the conditional Clayton copula is:

$$C^{Cla}(u_1|u_2) = \frac{\partial}{\partial u_2} (u_1^{-\theta} + u_2^{-\theta} - 1)^{-1/\theta} = u_1^{-(1+\theta)} (u_1^{-\theta} + u_2^{-\theta} - 1)^{-(1+\theta)/\theta},$$

such that $\theta > 0$. Given the equation $C^{Cla}(u_1|u_2) = q$, the q quantile for the Clayton copula is obtained as $u_1 = (1 + u_2^{-\theta}(q^{-\theta/(1+\theta)} - 1))^{-1/\theta}$ where $u_i = F_i(r_i)$.

If we set the marginals those from the bivariate pdf (I), then:

$$r_1 = F_1^{-1} \left[\left(1 + F_2(r_2)^{-\theta} (q^{-\theta/(1+\theta)} - 1) \right)^{-1/\theta} \right].$$

Draw the q quantile curves for $q = 0.05, 0.25, 0.5, 0.75, 0.95$ for the cases of $\theta = 2$ and $\theta = 4$.

Resolución:

Recordando las cdf marginales a las que el enunciado hace referencia:

$$F_1(r_1) = u_1 = 0.011025r_1^2 + 0.3222r_1 + 0.311175$$

$$F_1^{-1}(u_1) = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1)}}{2(0.011025)}$$

$$F_2(r_2) = u_2 = 0.0444r_2^2 + 0.2r_2 + 0.222$$

$$F_2^{-1}(u_2) = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2)}}{2(0.0444)}$$

Seguiremos el mismo procedimiento que en el ejercicio 8 para obtener los rendimientos dependientes y sus correspondientes curvas de cuantil.

- Caso $\theta = 2$:




Figura 13: Curvas de cuantil Clayton para $\theta = 2$

- Caso $\theta = 4$:




Figura 14: Curvas de cuantil Clayton para $\theta = 4$

En estos gráficos se puede comprobar que la dependencia de la Clayton en la cola de las pérdidas para ambos activos es mayor cuanto mayor es θ para todos los cuantiles.

Exercise 11

The four steps to simulate under a bivariate G copula with an alternative procedure are:

- (a) Find the Cholesky decomposition L of correlation matrix $\Psi = LL'$.
- (b) Generate draws (v_1, v_2) of independent $V_i \sim U(0, 1)$ to obtain draws $(z_1, z_2) = (\Phi^{-1}(v_1), \Phi^{-1}(v_2))$ of independent $Z_i \sim N(0, 1)$.
- (c) Generate draws $x = Lz$ with $z = (z_1, z_2)'$ of the bivariate $X = LZ \sim N(0, \Psi)$.
- (d) Set $u_i = \Phi(x_i)$ which are draws of the bivariate uniform (U_1, U_2) from the G copula.

Repeat Exercise 7 by using the above method. The expression of L is given by:

$$L = \begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{bmatrix}.$$

Resolución:

- (a) Consideremos la matriz de correlación:

$$\Psi = \begin{pmatrix} 1 & \rho_{12} & \rho_{13} & \cdots & \rho_{1n} \\ \rho_{12} & 1 & \rho_{23} & \cdots & \rho_{2n} \\ \rho_{13} & \rho_{23} & 1 & \cdots & \rho_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{1n} & \rho_{2n} & \rho_{3n} & \cdots & 1 \end{pmatrix}$$

Esta es una matriz simétrica y definida positiva. Para derivar la descomposición de Cholesky, consideremos L una matriz triangular inferior con entradas diagonales estrictamente positivas:

$$L = \begin{pmatrix} L_{11} & 0 & 0 & \cdots & 0 \\ L_{21} & L_{22} & 0 & \cdots & 0 \\ L_{31} & L_{32} & L_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ L_{n1} & L_{n2} & L_{n3} & \cdots & L_{nn} \end{pmatrix}, L^T = \begin{pmatrix} L_{11} & L_{21} & L_{31} & \cdots & L_{n1} \\ 0 & L_{22} & L_{32} & \cdots & L_{n2} \\ 0 & 0 & L_{33} & \cdots & L_{n3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & L_{nn} \end{pmatrix}$$

Al operar matricialmente estas matrices ($\Psi = LL^T$), se obtienen las siguientes ecuaciones, yendo fila por fila. Comencemos por la primera:

$$1 = L_{11} \cdot L_{11}$$

$$\rho_{1j} = L_{11} \cdot L_{j1}, \quad j = 2, \dots, n$$

Así, obtenemos los valores de la primera columna de L (nos vamos a quedar con la raíz positiva de los elementos de la diagonal):

$$\begin{aligned} L_{11} &= 1 \\ L_{j1} &= \rho_{1j}, \quad j = 2, \dots, n \end{aligned}$$

Sigamos operando con la segunda fila:

$$\begin{aligned} \rho_{12} &= L_{21} \cdot L_{11} + L_{22} \cdot 0 \\ 1 &= L_{21} \cdot L_{21} + L_{22} \cdot L_{22} \\ \rho_{2j} &= L_{21} \cdot L_{j1} + L_{22} \cdot L_{j2}, \quad j = 3, \dots, n \end{aligned}$$

Teniendo en cuenta que los elementos de la primera fila ya los hemos despejado, obtenemos los valores como sigue:

$$\begin{aligned} L_{22} &= \sqrt{1 - L_{21}^2} \\ L_{j2} &= \frac{\rho_{2j} - L_{21} \cdot L_{j1}}{L_{22}}, \quad j = 3, \dots, n \end{aligned}$$

De manera iterativa, suponiendo calculadas las primeras $k - 1$ filas y obviando las redundantes (como la primera ecuación mostrada en el paso 2), se tiene:

$$\begin{aligned} 1 &= \sum_{i=1}^k L_{ki}^2 = L_{kk}^2 + \sum_{i=1}^{k-1} L_{ki}^2 \\ \rho_{kj} &= \sum_{i=1}^k L_{ji} L_{ki} = L_{jk} L_{kk} + \sum_{i=1}^{k-1} L_{ji} L_{ki}, \quad j = k + 1, \dots, n \end{aligned}$$

De esta manera, podemos despejar en cada iteración una columna de L :

$$\begin{aligned} L_{kk} &= \sqrt{1 - \sum_{i=1}^{k-1} L_{ki}^2} \\ L_{jk} &= \frac{\rho_{kj} - \sum_{i=1}^{k-1} L_{ji} L_{ki}}{L_{kk}}, \quad j = k + 1, \dots, n \end{aligned}$$

Para el caso bivariante, como nos pide el enunciado, siguiendo el desarrollo anterior, obtendríamos que L es como sigue:

$$L = \begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{bmatrix}.$$

- (b) Generamos N simulaciones de v_1, v_2 de números uniformes, que se convierten en si-

mulaciones de números de la distribución normal $N(0, 1)$ como $(z_1, z_2) = (\Phi^{-1}(v_1), \Phi^{-1}(v_2))$, pues suponemos $v_i = \Phi(z_i)$, $i = 1, 2$.

- (c) Una vez hemos generado los números aleatorios de la normal independientes, introducimos la dependencia de la matriz de correlación de la cópula gaussiana bivalente a través de su descomposición de Cholesky, como hemos derivado anteriormente. En este caso bivalente, obtenemos los números aleatorios dependientes de la normal bivalente correlacionada $X \sim N(0, \Psi)$ como sigue,

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \Rightarrow$$

$$x_1 = z_1$$

$$x_2 = \rho z_1 + \sqrt{1 - \rho^2} z_2$$

- (d) Tenemos que $u_2 = \Phi(x_2)$ y $u_1 = \Phi(x_1)$. Efectuando la comparación con el ejercicio 7, como solicita el enunciado, tenemos por un lado que $x_1 = z_1 = \Phi^{-1}(v_1)$. Por tanto, se tiene que $u_1 = \Phi(\Phi^{-1}(v_1)) = v_1$. Esto contrasta con la operativa del ejercicio 7, donde teníamos $u_2 = v_2$, ya que agregábamos la dependencia de la cópula en los rendimientos del primer activo $C^G(u_1|u_2^*)$, en este caso, la dependencia se incluye en el rendimiento del segundo activo.

En este sentido, incluyendo la dependencia con la cópula se tenía que

$$u_1 = \Phi\left(\rho\Phi^{-1}(v_2) + \sqrt{1 - \rho^2}\Phi^{-1}(v_1)\right).$$

Ahora la dependencia que incluimos en el segundo activo es

$u_2 = \Phi\left(\rho\Phi^{-1}(v_1) + \sqrt{1 - \rho^2}\Phi^{-1}(v_2)\right)$, es decir, es la misma dependencia pero invirtiendo el orden. Esto tiene todo el sentido, teniendo en cuenta la generación de números independientes, ya que usando una matriz triangular inferior es el primer activo el independiente y cuando generamos números dependientes a través de la cópula, es el último activo el independiente y los demás se simulan con la dependencia extraída de la cópula condicional.

Repetiremos ahora el ejercicio 7, generando los números aleatorios de esta manera.




Figura 15: Conditional Sampling Simulation

Obtenemos unos scatterplots muy semejantes a los del ejercicio 7, como era de esperar. Veamos ahora qué sucede con la cartera formada. Probablemente cambie, dada la composición de la cartera y la forma en la que estamos generando los rendimientos (la dependencia se incluye en el otro activo).

Para ahora obtener los momentos de la cartera $\mathbf{D}$, una vez tenemos las $i = 1, \dots, 10000$ simulaciones de los rendimientos $r_{1,i}^*$ y $r_{2,i}^*$, calculamos los rendimientos de la cartera como sigue:

$$r_{p,i}^D = 0.25 \cdot r_{1,i}^* + 0.75 \cdot r_{2,i}^*$$

- **Media:** $\hat{\mu}_p^D = \frac{1}{N} \sum r_{p,i}^D$
- **Desviación Típica:** $\hat{\sigma}_p^D = \sqrt{\frac{1}{N-1} \sum (r_{p,i}^D - \hat{\mu}_p^D)^2}$
- **VaR Histórico:** Corresponde a los cuantiles al 1 % y 5 % de la distribución simulada.

Tras realizar las 10,000 simulaciones en Python, los resultados son los siguientes.

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^D$)	0.8501
Desviación Típica ($\hat{\sigma}_p^D$)	0.6993
VaR ^D 1 %	-0.8432
VaR ^D 5 %	-0.4678

Tabla 4: Estadísticos descriptivos y VaR de la Cartera $\mathbf{D}$

Adjuntamos el histograma de la cartera $\mathbf{D}$ junto con la distribución normal, donde observamos, como se comprueba en los estadísticos descriptivos anteriores, que parece que esta

cartera varía ligeramente en rendimiento con respecto a la del ejercicio 7, sin embargo, es muy semejante, como debería ocurrir en cierta medida.




Figura 16: Histograma de la Cartera D

Exercise 12

Using the Cholesky decomposition in Exercise 11 is easy to simulate draws from the bivariate Student t copula (hereafter, T copula). The steps (a) and (b) are the same;

- (c) Simulate a draw s from the random variate χ_ν^2 independent of Z .
- (d) Generate draws $y = \sqrt{(\nu/s)}x$ where $x = Lz$ with $z = (z_1, z_2)'$ of the bivariate $X = LZ \sim N(0, \Psi)$.
- (e) Set $u_i = T_\nu(y_i)$ where T_ν denotes the cdf of the univariate Student t distribution.

Definitively, $u_i = T_\nu(y_i)$ are draws of the bivariate uniform (U_1, U_2) from the T copula.

Repeat Exercise 7 by using the T copula instead of the G copula with marginals those from the bivariate pdf (I). Consider $\rho = -0.7$ and $\nu = 5$. Obtain both the sample mean and standard deviation of the portfolio $\mathbf{E}$ returns, containing 25 % of stock 1 and 75 % of stock 2 under the above procedure, and also the VaR values at 1 % and 5 %.

Resolución:

- (a) Utilizamos la siguiente matriz de Cholesky, derivada en el ejercicio anterior para el caso bivalente:

$$L = \begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{bmatrix}.$$

- (b) Generamos N simulaciones de v_1, v_2 de números uniformes, que se convierten en simulaciones de números de la distribución normal $N(0, 1)$ como $(z_1, z_2) = (\Phi^{-1}(v_1), \Phi^{-1}(v_2))$, pues suponemos $v_i = \Phi(z_i)$, $i = 1, 2$.
- (c) Cabe destacar cómo se construye la variable t de Student multivariante en este punto. Dadas $\mathbb{X} \sim N(0, \Sigma)$ y $S \sim \chi_\nu^2$, la variable aleatoria generada como sigue es una t de Student de ν grados de libertad:

$$\mathbb{T} = \frac{\mathbb{X}}{\sqrt{\frac{S}{\nu}}} = \sqrt{\frac{\nu}{S}} \mathbb{X} \sim t_\nu$$

La estructura de correlación de la $\mathbb{T}$ multivariante viene dada por la estructura de la $\mathbb{X}$ multivariante. La distribución χ_ν^2 por tanto, solo sirve como factor de escala, si generásemos más de un valor de ella, perderíamos la estructura de dependencia en la t multivariante y obtendríamos varias t univariantes independientes. Es por ello que solo debemos generar un único valor de la distribución χ^2 por simulación, en

vez de tantos valores como número de valores estemos generando de la normal (o t).

Por tanto, para generar una simulación de N valores de la distribución t de Student de ν grados de libertad, tiene sentido generar N valores de una distribución χ^2 de ν grados de libertad, a mayores de los N valores de una distribución normal estándar ya generados.

- (d) Una vez generados los N valores independientes de la normal estándar (z_1, z_2) , obtenemos los valores correlacionados de la variable aleatoria $X \sim N(0, \Psi)$ como sigue, a partir de la descomposición de Cholesky:

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \Rightarrow$$

$$x_1 = z_1$$

$$x_2 = \rho z_1 + \sqrt{1 - \rho^2} z_2$$

Una vez obtenemos los valores normales dependientes, generamos un valor $s \sim \chi_\nu^2$ y obtenemos los valores con distribución t_ν como sigue:

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \sqrt{\frac{\nu}{s}} \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

- (e) Tras obtener los valores (y_1, y_2) , obtenemos los valores $(u_1, u_2) = (T_\nu(y_1), T_\nu(y_2))$ con los que generaremos los rendimientos dependientes de las marginales de (I).

Repitiendo el ejercicio 7, obtenemos lo siguiente, empleando una correlación de $\rho = -0.7$ y grados de libertad $\nu = 5$.




Figura 17: Conditional Sampling Simulation

Aunque no se aprecie muy bien, en esta generación, al usar una t , tenemos más valores extremos (en las esquinas superior derecha e inferior izquierda), como debería suceder, al usar esta cópula con mayor peso en las colas que la normal.

Para ahora obtener los momentos de la cartera $\mathbf{E}$, una vez tenemos las $i = 1, \dots, 10000$ simulaciones de los rendimientos $r_{1,i}^*$ y $r_{2,i}^*$, calculamos los rendimientos de la cartera como sigue:

$$r_{p,i}^{\mathbf{E}} = 0.25 \cdot r_{1,i}^* + 0.75 \cdot r_{2,i}^*$$

- **Media:** $\hat{\mu}_p^{\mathbf{E}} = \frac{1}{N} \sum r_{p,i}^{\mathbf{E}}$
- **Desviación Típica:** $\hat{\sigma}_p^{\mathbf{E}} = \sqrt{\frac{1}{N-1} \sum (r_{p,i}^{\mathbf{E}} - \hat{\mu}_p^{\mathbf{E}})^2}$
- **VaR Histórico:** Corresponde a los cuantiles al 1 % y 5 % de la distribución simulada.

Tras realizar las 10,000 simulaciones en Python, los resultados son los siguientes.

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^{\mathbf{E}}$)	0.8468
Desviación Típica ($\hat{\sigma}_p^{\mathbf{E}}$)	0.7060
VaR $^{\mathbf{E}}$ 1 %	-0.8807
VaR $^{\mathbf{E}}$ 5 %	-0.4905

Tabla 5: Estadísticos descriptivos y VaR de la Cartera $\mathbf{E}$

Adjuntamos el histograma de la cartera $\mathbf{E}$ junto con la distribución normal, donde observamos, como se comprueba en los estadísticos descriptivos anteriores, que parece que esta cartera varía ligeramente en rendimiento con respecto a la del ejercicio 11, sin embargo, es muy semejante igualmente a las obtenidas previamente.




Figura 18: Histograma de la Cartera $\mathbf{E}$

Exercise 13

Compute the sample covariance and correlation matrices of the portfolio return series A, B, C, D and E already obtained in Exercises 3, 6, 7 and 12. Obtain also the skewness and kurtosis of each of them.

Build an equally weighted (EW) portfolio series containing the five portfolio return series. Compute the mean, variance, skewness and kurtosis of the EW return series. Obtain the QQ plot of the standardized EW return series.

Resolución:

Para obtener las matrices de covarianza y correlación, así como la asimetría y la curtosis de las distintas carteras, una vez obtenidos los rendimientos de estos en Python, utilizaremos las funciones descritas del programa para calcularlas. Cabe destacar que las covarianzas y correlaciones muestrales las calcula con $N - 1$ grados de libertad, aunque dado que tenemos una muestra de $N = 10000$, esto no debe afectar mucho al cálculo. Sin más dilación, mostremos los resultados.

- Matriz de covarianzas muestrales:

$$\hat{\Sigma} = \begin{matrix} & \begin{matrix} A & B & C & D & E \end{matrix} \\ \begin{matrix} A \\ B \\ C \\ D \\ E \end{matrix} & \begin{pmatrix} 0.605754 & 0.654262 & -0.005752 & -0.003492 & -0.003310 \\ 0.654262 & 0.710050 & -0.006877 & -0.004136 & -0.003849 \\ -0.005752 & -0.006877 & 0.802959 & 0.004175 & 0.005296 \\ -0.003492 & -0.004136 & 0.004175 & 0.491267 & -0.006663 \\ -0.003310 & -0.003849 & 0.005296 & -0.006663 & 0.498451 \end{pmatrix} \end{matrix}$$

- Matriz de correlaciones muestrales:

$$\hat{\Psi} = \begin{matrix} & \begin{matrix} A & B & C & D & E \end{matrix} \\ \begin{matrix} A \\ B \\ C \\ D \\ E \end{matrix} & \begin{pmatrix} 1.000000 & 0.997606 & -0.008248 & -0.006402 & -0.006025 \\ 0.997606 & 1.000000 & -0.009107 & -0.007002 & -0.006470 \\ -0.008248 & -0.009107 & 1.000000 & 0.006648 & 0.008372 \\ -0.006402 & -0.007002 & 0.006648 & 1.000000 & -0.013465 \\ -0.006025 & -0.006470 & 0.008372 & -0.013465 & 1.000000 \end{pmatrix} \end{matrix}$$

- Asimetría de las distintas carteras:

Cartera	Asimetría
<i>A</i>	-0.527081
<i>B</i>	-0.495594
<i>C</i>	-0.448102
<i>D</i>	-0.605872
<i>E</i>	-0.608617

Tabla 6: Asimetría de las distintas carteras

- Curtosis de las distintas carteras:

Cartera	Curtosis
<i>A</i>	5.425293
<i>B</i>	5.415921
<i>C</i>	5.332456
<i>D</i>	5.441263
<i>E</i>	5.514945

Tabla 7: Curtosis de las distintas carteras

Las correlaciones entre todas las carteras son prácticamente 0 ya que, además de que la dependencia entre los rendimientos se modeliza de manera diferente, en cada cartera se generan nuevos números aleatorios sin emplear Common Random Numbers. Por tanto, es lógico que se obtengan estos resultados. Las únicas carteras que tienen una correlación alta (de hecho, prácticamente 1), son las carteras ***A*** y ***B***, donde se han generado con distintas marginales pero mismos números aleatorios y misma dependencia, de ahí la correlación tan alta.

En cuanto a la asimetría y la curtosis, vistos los histogramas en comparación con la normal, es evidente que son distribuciones asimétricas y con colas más pesadas, como muestran los estadísticos.

Obtendremos ahora la cartera con pesos equidistantes (*EW*) como sigue,

$$r_j^{EW} = \frac{1}{5} \sum_{i=A}^E r_j^i, i = A, B, C, D, E, j = 1, \dots, 10000$$

con sus respectivos estadísticos.

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^{EW}$)	0.836757
Varianza ($\hat{\sigma}_p^{2,EW}$)	0.174712
Asimetría	-0.323112
Curtosis	2.802356

Tabla 8: Estadísticos descriptivos de la Cartera Equiponderada (EW)




Figura 19: QQ-Plot: EW (Estandarizado) vs Normal

Como podemos observar, por el efecto de la diversificación, tanto en el QQ-Plot frente a la normal como en los propios estadísticos de asimetría y curtosis, los rendimientos de esta cartera equiponderada se asemejan más a una normal, con menor peso en las colas y menor asimetría también.

Exercise 14

Consider Exercise 11 for the trivariate G copula with correlation matrix:

$$\Psi = \begin{bmatrix} 1 & \rho_{12} & \rho_{13} \\ \rho_{12} & 1 & \rho_{23} \\ \rho_{13} & \rho_{23} & 1 \end{bmatrix}.$$

Show that $X = LZ \sim N(0, \Psi)$ where L is the Cholesky decomposition of $\Psi = LL'$ given by:

$$L = \begin{bmatrix} 1 & 0 & 0 \\ \rho_{12} & \sqrt{1 - \rho_{12}^2} & 0 \\ \rho_{13} & \frac{\rho_{23} - \rho_{12}\rho_{13}}{\sqrt{1 - \rho_{12}^2}} & \sqrt{1 - \rho_{13}^2 - \left(\frac{\rho_{23} - \rho_{12}\rho_{13}}{\sqrt{1 - \rho_{12}^2}}\right)^2} \end{bmatrix}.$$

Resolución:

Ya hemos derivado el algoritmo para la descomposición de Cholesky para una matriz de correlación de orden n , donde es sencillo comprobar que, empleando ese algoritmo, se obtiene la matriz descrita en el enunciado. Comprobemos que el vector aleatorio X generado de esta manera sigue una $N(0, \Psi)$.

Cualquier combinación lineal de un vector normal, en este caso, $Z \sim N(0, I)$, mantiene su distribución, por tanto, X también será normal. Calculemos los momentos que caracterizan a esta distribución.

- Media:

$$\mathbb{E}[X] = \mathbb{E}[LZ] = L \cdot \mathbb{E}[Z] = L \cdot 0 = 0$$

- Matriz de covarianzas:

$$\mathbb{V}[X] = \mathbb{V}[LZ] = L \cdot \mathbb{V}[Z] \cdot L' = L \cdot I \cdot L' = LL' = \Psi$$

Siendo la última igualdad dada por el enunciado, por ser L la descomposición de Cholesky de Ψ .

Por tanto, queda demostrado que $X = LZ \sim N(0, \Psi)$.

Exercise 15

Consider the three daily return series (Apple, Amazon and Pfizer) in file "stocks.xlsx", each with length $T = 3,892$. Answer the following questions:

- i) Plot the empirical distribution function (EDF) for each standardized return series (you can use `cdfplot` in Python).

Hint 1: See EDF in https://en.wikipedia.org/wiki/Empirical_distribution_function

- ii) Assume a trivariate G copula pdf, see section i) in Exercise 4 for the bivariate case. Estimate the correlation matrix under maximum likelihood (ML) with input series: $\hat{\eta}_t = (\Phi^{-1}(\hat{u}_{1t}), \Phi^{-1}(\hat{u}_{2t}), \Phi^{-1}(\hat{u}_{3t}))'$, $t = 1, \dots, T$ such that $\hat{u}_{it}$ is EDF_i .

Hint 2: The ML estimation of Ψ is given by $\hat{\Psi}_{ML} = T^{-1} \sum_{t=1}^T \hat{\eta}_t \hat{\eta}_t'$ with $\hat{\eta}_{it} = \Phi^{-1}(\hat{u}_{it})$. The correlation matrix estimation can be renormalized so that all diagonal elements equal one.

- iii) Generate by Monte Carlo an equally weighted (EW) portfolio series of length $N = 10,000$ containing the three stocks under the G copula with $\hat{\Psi}_{ML}$ obtained in section ii), and marginal distribution for the stock return i given by:

$$R_i = \mu_i + \sigma_i Z_i; \quad Z_i \sim ST_{\nu_i}; \quad E(Z_i) = 0, \quad E(Z_i^2) = 1,$$

with $ST_{\nu_i} = \sqrt{\frac{\nu_i - 2}{\nu_i}} T_{\nu_i}$ as the standardized Student-T distribution with degrees of freedom $\nu_i > 2$. The estimation of ν_i is based on either ML or MM (method-of-moments), the estimation of μ_i and σ_i are the sample mean and standard deviation of the stock return i . Compute the sample mean, standard deviation, skewness, kurtosis and VaR (1% and 5%) for the EW portfolio return series.

Resolución:

- i) La EDF es la función de distribución asociada a una muestra, en vez de a la distribución poblacional. Mostraremos ahora un gráfico donde pintamos la EDF de las tres compañías, incluyendo la cdf de la normal, para compararla con su distribución "teórica". Cabe mencionar que se obtiene como $EDF^{EMP}(x) = \frac{n^o \text{ observaciones} \leq x}{T} = \frac{1}{T} \sum_{i=1}^T \mathbb{1}_{\{r_i^{EMP} \leq x\}}$, $EMP = \text{Apple, Amazon, Pfizer}$.

En este contexto, si en la muestra no hay ningún rendimiento por debajo de 5 por ejemplo, $EDF(x) = 0 \quad \forall x < 5$. Si, por ejemplo, el mayor rendimiento de la muestra es 4, se tiene que $EDF(x) = 1 \quad \forall x \geq 4$. Empleando esta fórmula configuraremos los gráficos en nuestro software.




Figura 20: EDF Apple, Amazon y Pfizer vs CDF Normal

- II) Dada la serie de rendimientos de cada activo, $\{r_t^{EMP}\}_{t=1,\dots,T}$, obtenemos el valor de u_t^{EMP} como $EDF^{EMP}(r_t^{EMP}) = u_t^{EMP}$.

Una vez obtenemos la serie de valores uniformes para cada activo, como en los demás ejercicios, obtenemos el vector temporal η_t como la inversa de la cdf de la normal para estos valores uniformes obtenidos.

Es decir, $\eta_t^{EMP} = \Phi^{-1}(u_t^{EMP})$.

Una vez obtenemos el vector $\eta_t = (\eta_t^{AAPL}, \eta_t^{AMZN}, \eta_t^{PFE})$, se calcula la estimación máximo verosímil de la matriz de correlaciones como $\hat{\Psi}_{ML} = T^{-1} \sum_{t=1}^T \hat{\eta}_t \hat{\eta}_t'$. Para renormalizarla, de manera que todos los elementos de la diagonal sean iguales a 1, para cada elemento i, j de la matriz $\hat{\Psi}_{ML}$, efectuamos la siguiente transformación:

$$(\hat{\Psi}_{ML})_{i,j} = \frac{(\hat{\Psi}_{ML})_{i,j}}{\sqrt{(\hat{\Psi}_{ML})_{i,i} \cdot (\hat{\Psi}_{ML})_{j,j}}}.$$

Tras implementar esto en Python, obtenemos la siguiente estimación:

$$\hat{\Psi}_{ML} = \begin{matrix} & \begin{matrix} AAPL & AMZN & PFE \end{matrix} \\ \begin{matrix} AAPL \\ AMZN \\ PFE \end{matrix} & \begin{pmatrix} 1.000000 & 0.420189 & 0.302948 \\ 0.420189 & 1.000000 & 0.347288 \\ 0.302948 & 0.347288 & 1.000000 \end{pmatrix} \end{matrix}$$

- III) Tenemos que separar en varias etapas este procedimiento para simular rendimientos

de estos tres activos bajo la cópula gaussiana.

1. Debemos calcular la media y desviación estándar muestral de cada serie de rendimientos. Utilizaremos el método de los momentos para estimar los grados de libertad de cada distribución t de Student estándar.

Los grados de libertad de una t de Student es un parámetro del modelo. Distintos momentos de la distribución poblacional dependen de este parámetro, como lo pueden ser la varianza ($\sigma^2 = \frac{\nu}{\nu-2}$) y el exceso de curtosis ($\kappa = \frac{6}{\nu-4}$). El método de los momentos básicamente nos dice que podemos obtener la estimación de este parámetro del modelo (ν) igualando con la estimación muestral de uno de estos momentos. Dado que queremos trabajar con la t estandarizada (varianza unitaria), estimaremos los grados de libertad de cada activo con la curtosis. Es decir, obtendremos la curtosis muestral también de cada serie de rendimientos y a partir de esta estimaremos los grados de libertad de la distribución t . En efecto, $\hat{\kappa} = \frac{6}{\hat{\nu}-4} \Rightarrow \hat{\nu} = \frac{6+4\hat{\kappa}}{\hat{\kappa}}$.

2. Descompondremos la matriz de correlación obtenida en ii) en la matriz de Cholesky, $\hat{\Psi}_{ML} = LL'$. En este momento, generaremos por cada simulación $i = 1, \dots, 10000$ tres valores aleatorios normales (v_1, v_2, v_3) y los haremos dependientes a través de la estructura de la cópula (mantenida en la descomposición de Cholesky) como en los ejercicios anteriores.

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ \rho_{12} & \sqrt{1-\rho_{12}^2} & 0 \\ \rho_{13} & \frac{\rho_{23}-\rho_{12}\rho_{13}}{\sqrt{1-\rho_{12}^2}} & \sqrt{1-\rho_{13}^2-\left(\frac{\rho_{23}-\rho_{12}\rho_{13}}{\sqrt{1-\rho_{12}^2}}\right)^2} \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} \Rightarrow$$

$$x_1 = v_1$$

$$x_2 = \rho_{12}v_1 + \sqrt{1-\rho_{12}^2}v_2$$

$$x_3 = \rho_{13}v_1 + \frac{\rho_{23}-\rho_{12}\rho_{13}}{\sqrt{1-\rho_{12}^2}}v_2 + \sqrt{1-\rho_{13}^2-\left(\frac{\rho_{23}-\rho_{12}\rho_{13}}{\sqrt{1-\rho_{12}^2}}\right)^2}v_3$$

3. Una vez obtenemos para cada simulación los valores normales correlados, extraemos esta información y lo trasparamos a valores uniformes. Es decir, $(u_1, u_2, u_3) = (\Phi(x_1), \Phi(x_2), \Phi(x_3))$.
 4. Obtenemos valores de la distribución t de Student con los grados de libertad obtenidos para cada activo como sigue: $(y_1, y_2, y_3) = (T_{\hat{\nu}_1}^{-1}(u_1), T_{\hat{\nu}_2}^{-1}(u_2), T_{\hat{\nu}_3}^{-1}(u_3))$.
 5. Estandarizamos estos valores como sugiere el enunciado
- $$(z_1, z_2, z_3) = \left(\sqrt{\frac{\hat{\nu}_1-2}{\hat{\nu}_1}}y_1, \sqrt{\frac{\hat{\nu}_2-2}{\hat{\nu}_2}}y_2, \sqrt{\frac{\hat{\nu}_3-2}{\hat{\nu}_3}}y_3 \right)$$

6. Una vez tenemos los valores de la t estandarizada obtenemos la simulación del rendimiento de cada activo como indica el enunciado:

$$(r_1, r_2, r_3) = (\hat{\mu}_1 + \hat{\sigma}_1 z_1, \hat{\mu}_2 + \hat{\sigma}_2 z_2, \hat{\mu}_3 + \hat{\sigma}_3 z_3)$$

Empleando este algoritmo, obtenemos los siguientes resultados:

Estadístico	Valor Estimado
Media ($\hat{\mu}_p^{\text{EW}}$)	0.000853
Desviación Típica ($\hat{\sigma}_p^{\text{EW}}$)	0.015403
Asimetría	-0.037634
Curtosis	4.982912
VaR ^{EW} 1 %	-0.038928
VaR ^{EW} 5 %	-0.023578

Tabla 9: Estadísticos descriptivos y VaR de la Cartera EW (Cópula G y marginales ST)

Exercise 16

The cdf of the conditional copula for a bivariate Normal mixture (NM) copula is easy to derive from the bivariate G copula in Exercise 7:

$$C^{NM}(u_1|u_2) = \pi \times \Phi \left(\frac{\Phi^{-1}(u_1) - \rho_1 \Phi^{-1}(u_2)}{\sqrt{1 - \rho_1^2}} \right) + (1 - \pi) \times \Phi \left(\frac{\Phi^{-1}(u_1) - \rho_2 \Phi^{-1}(u_2)}{\sqrt{1 - \rho_2^2}} \right),$$

where $0 < \pi < 1$. However, this time the q quantile curves cannot be expressed as an explicit function and numerical methods need to be used to back out a value of u_2 from $C^{NM}(u_1|u_2) = q$ from each u_1 and q .

If we set the marginals $F_i(\bullet)$ $i = 1, 2$ those from the bivariate pdf (I), i.e., $r_i = F_i^{-1}(u_i)$. Draw the q quantile curves for $q = 0.05, 0.25, 0.5, 0.75, 0.95$ when $\pi = 0.3$, $\rho_1 = -0.7$, $\rho_2 = 0.4$.

Resolución:

Recordamos las cdf marginales que solicita el enunciado:

$$F_1(r_1) = u_1 = 0.011025r_1^2 + 0.3222r_1 + 0.311175$$

$$F_1^{-1}(u_1) = r_1 = \frac{-0.3222 + \sqrt{0.3222^2 - 4(0.011025)(0.311175 - u_1)}}{2(0.011025)}$$

$$F_2(r_2) = u_2 = 0.0444r_2^2 + 0.2r_2 + 0.222$$

$$F_2^{-1}(u_2) = r_2 = \frac{-0.2 + \sqrt{0.2^2 - 4(0.0444)(0.222 - u_2)}}{2(0.0444)}$$

Al contrario de lo efectuado en los ejercicios 8 y 9, donde podíamos despejar analíticamente u_1 , dado un cuantil q , en este ejercicio debemos obtener el valor de u_1 condicional a u_2 mediante un método numérico.

Lo que haremos será lo siguiente, simularemos un número aleatorio u_2 y obtendremos su rendimiento asociado analíticamente r_2 .

Tras esto, dado que no podemos resolver la ecuación $C^{NM}(u_1|u_2) = q$ analíticamente, trataremos de encontrar la raíz de la función $C^{NM}(u_1|u_2) - q = 0$, donde esto sí que lo podemos resolver con algoritmos numéricos. Esto se podría resolver empleando el algoritmo de Newton-Raphson por ejemplo, sin embargo, el algoritmo podría tratar de evaluar en alguna iteración fuera del intervalo de interés $(0, 1)$ y dar problemas numéricos, al intentar evaluar $\Phi^{-1}(u_1)$ en un punto fuera de este intervalo. Por tanto, el algoritmo de búsqueda que realizaremos será el método de Brent, que combina distintos algoritmos iterativos, incluido el método de Newton-Raphson (realmente el método de la secante, donde

se aproxima numéricamente la derivada) y tiene la ventaja frente a este que las distintas evaluaciones de la función no salen del dominio elegido. En nuestro caso de interés, nuestro algoritmo no podría tratar de evaluar u_1 fuera del intervalo $(0, 1)$ porque daría problemas numéricos, por lo que adoptamos esta solución.

Una vez obtenemos u_1 con la dependencia de la cópula mixtura de normales y en el cuantil deseado, obtenemos analíticamente r_1 .




Figura 21: Curvas de cuantil mixtura de normales

Como podemos observar, comparando con el ejercicio 8, donde se ha simulado con una única cópula y las mismas marginales, la dependencia es bastante diferente al incluir la mezcla de normales. En el anterior ejercicio, había una clara pendiente negativa en las curvas de cuantil (mostrada por la pendiente negativa de todas, debido al único coeficiente de correlación ($\rho_1 = -0.7$) negativo implícito en la cópula).

En este caso, al incluir una normal a mayores con dependencia positiva entre ambos rendimientos ($\rho_2 = 0.4$), además de que esta normal tiene mayor probabilidad en la mixtura ($1 - \pi = 0.7$), esta pendiente negativa se suaviza y obtenemos curvas de cuantil más horizontales, como se puede observar, además de distintos comportamientos según el rendimiento de r_1 o r_2 . Parece que aporta una dependencia más diversa la mixtura.

Exercise 17

Repeat the same analysis as in section iv) in Exercise 3 but considering as marginal distributions for the returns the Truncated Normal (TN) distribution, $R_i \sim TN(a_i, b_i, \tilde{\mu}_i, \tilde{\sigma}_i)$ with pdf:

$$f_i(r_i) = \frac{1}{\tilde{\sigma}_i} \frac{\phi((r_i - \tilde{\mu}_i)/\tilde{\sigma}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)}$$

such that $a_i < r_i < b_i$, $\tilde{\sigma}_i > 0$, $\tilde{a}_i = (a_i - \tilde{\mu}_i)/\tilde{\sigma}_i$ and $\tilde{b}_i = (b_i - \tilde{\mu}_i)/\tilde{\sigma}_i$. Both mean and standard deviation of R_i , denoted as μ_i and σ_i , are:

$$\mu_i = \tilde{\mu}_i - \tilde{\sigma}_i B_i; \quad \sigma_i = \tilde{\sigma}_i \sqrt{1 - A_i - B_i^2};$$

$$A_i = \frac{\tilde{b}_i \phi(\tilde{b}_i) - \tilde{a}_i \phi(\tilde{a}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)}; \quad B_i = \frac{\phi(\tilde{b}_i) - \phi(\tilde{a}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)}.$$

By using the inverse transform method for simulated random variables, we have:

$$R_i = \tilde{\mu}_i + \tilde{\sigma}_i \cdot \Phi^{-1}(\Phi(\tilde{a}_i) + U_i \cdot [\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)]); \quad i = 1, 2$$

where $\phi(\cdot)$ and $\Phi(\cdot)$ denote, respectively, pdf and cdf of the $N(0, 1)$ distribution, and (U_1, U_2) is a bivariate uniform random vector under the conditional sampling in section iv) in Exercise 3. The values of (a_i, b_i) are the same as those in Exercise 3, while μ_i and σ_i are set to be equal to those from the implied marginal distribution of R_i in the pdf (I). Thus, $(\mu_1, \sigma_1) = (0.55, 0.86)$ and $(\mu_2, \sigma_2) = (0.93, 1.11)$.

Compute both the sample mean and standard deviation of portfolio F returns, containing 25 % of stock 1 and 75 % of stock 2 under the above procedure, and also the VaR values at 1 % and 5 %. Compare these VaR values of portfolio F with those from portfolios A and B.

Hint: See https://en.wikipedia.org/wiki/Truncated_normal_distribution

Resolución:

El ejercicio nos pide replicar la cópula del ejercicio 3 sirviéndonos del teorema de Sklar para reemplazar las distribuciones marginales Triangulares (Ejercicio 3) por Normales Truncadas, manteniendo los mismos valores del soporte de r_1 y r_2 , la media μ y la volatilidad σ , y la estructura de dependencia o la cópula del ejercicio 3.

La pdf de esta normal truncada está expresada en el enunciado y tiene la particularidad de estar truncada en el intervalo $[a, b]$. Recuperando los valores del soporte del ejercicio

3, tenemos que $a_1 = -1, b_1 = 2, a_2 = -2$ y $b_2 = 2.5$. Y la media y desviación típica eran $\mu_1 = 0.55, \sigma_1 = 0.86, \mu_2 = 0.93$ y $\sigma_2 = 1.11$.

Para calcular $\tilde{\mu}$ y $\tilde{\sigma}$, que no coinciden con la media y desviación típica observadas (μ, σ) del activo dado que están truncadas, debemos hallar los parámetros $(\tilde{\mu}, \tilde{\sigma})$ resolviendo un sistema de 2 ecuaciones no lineales y 2 incógnitas que se detalla en el enunciado. Sustituyendo A_i y B_i y elevando la volatilidad al cuadrado para quitarnos las raíces, el sistema es:

$$\mu_i = \tilde{\mu}_i - \tilde{\sigma}_i \left[\frac{\phi(\tilde{b}_i) - \phi(\tilde{a}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)} \right]$$

$$\sigma_i^2 = \tilde{\sigma}_i^2 \left[1 - \frac{\tilde{b}_i \phi(\tilde{b}_i) - \tilde{a}_i \phi(\tilde{a}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)} - \left(\frac{\phi(\tilde{b}_i) - \phi(\tilde{a}_i)}{\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)} \right)^2 \right]$$

Este procedimiento consiste en calibrar los parámetros para que la distribución truncada se parezca lo máximo posible a la triangular en términos de media y de varianza. Dado que no se puede resolver este sistema a mano, utilizamos un optimizador o solver que nos calcule los valores de $\tilde{\mu}_i$ y $\tilde{\sigma}_i$ que hagan posibles los valores para los activos 1 y 2.

Tras ejecutar el solver, los resultados son:

$$\begin{aligned} \text{Activo 1: } \tilde{\mu}_1 &= 2.196482, & \tilde{\sigma}_1 &= 5.012776 \\ \text{Activo 2: } \tilde{\mu}_2 &= 2.686932, & \tilde{\sigma}_2 &= 2.228705 \end{aligned}$$

Para la simulación, empleamos el Método de la Transformada Inversa facilitado por el enunciado utilizando los mismos vectores de uniformes dependientes (U_1, U_2) generados en el Ejercicio 3. Esto es crucial para mantener la estructura de dependencia original, ya que generar nuevas uniformes rompería la correlación histórica de la cópula.

La fórmula de simulación para cada activo i es:

$$R_i = \tilde{\mu}_i + \tilde{\sigma}_i \cdot \Phi^{-1} \left[\Phi(\tilde{a}_i) + U_i \cdot (\Phi(\tilde{b}_i) - \Phi(\tilde{a}_i)) \right]$$

Tras realizar la simulación con los parámetros calibrados, obtenemos los estadísticos de la Cartera F y los comparamos con la Cartera A (Triangular) y la Cartera B (Original) para comprobar cuánto afecta el modificar la distribución marginal en media, volatilidad y riesgo.

Tabla 10: Comparativa de Resultados: Cartera F vs A vs B

Estadístico	Cartera F (TN)	Cartera A (Triangular)	Cartera B (Original)
Media ($\hat{\mu}_p$)	0.8400	0.8391	0.8310
Volatilidad ($\hat{\sigma}_p$)	0.8531	0.7880	0.7062
VaR 1 %	-1.2376	-1.0351	-0.8749
VaR 5 %	-0.7642	-0.6129	-0.5124

Al comparar los resultados (Tabla 10), se observa una notable estabilidad en la media, que varía mínimamente entre 0.83 y 0.84 en los tres modelos, lo cual confirma la consistencia de la calibración.

Sin embargo, en las métricas de riesgo sí observamos diferencias significativas.

$$\text{VaR}(\text{Original}) < \text{VaR}(\text{Triangular}) < \text{VaR}(\text{Normal Truncada})$$

El incremento del riesgo en la Cartera F (VaR 1 % de -1.24) respecto a la A (-1.04) y la B (-0.87) es consecuencia directa de la forma de las distribuciones marginales. La distribución Triangular decae linealmente hasta cero en los extremos, asignando muy poca probabilidad a los valores extremos. En contraste, la Normal Truncada, al ser una "campana cortada", conserva una densidad de probabilidad superior cerca de las cotas del soporte (a, b) .

Por tanto, el modelo de Normal Truncada resulta ser el más conservador. Esto sugiere que, ante la incertidumbre sobre la forma real de la distribución en las colas, asumir una Normal Truncada proporciona una seguridad mayor que la distribución Triangular o la Original.




Figura 22: Cartera F: Normal Truncada